



机械科学与技术

Mechanical Science and Technology for Aerospace Engineering

ISSN 1003-8728, CN 61-1114/TH

《机械科学与技术》网络首发论文

题目: 纹理表面缺陷机器视觉检测方法综述
作者: 朱贺, 杨华, 尹周平
DOI: 10.13433/j.cnki.1003-8728.20220086
网络首发日期: 2022-03-17
引用格式: 朱贺, 杨华, 尹周平. 纹理表面缺陷机器视觉检测方法综述[J/OL]. 机械科学与技术. <https://doi.org/10.13433/j.cnki.1003-8728.20220086>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

纹理表面缺陷机器视觉检测方法综述

朱贺¹, 杨华¹, 尹周平¹

(1. 华中科技大学 机械科学与工程学院 数字制造装备与技术国家重点实验室, 武汉 430000)

摘要：纹理表面缺陷检测在机器视觉领域具有意义和挑战性，其历史可以追溯到 20 世纪中后期，近年来随着深度学习技术的蓬勃发展，纹理表面缺陷检测技术大幅飞跃。直至今日，关于纹理表面缺陷检测的调研和综述仍然很少，在此背景下，我们全面回顾了 2017 年-2021 年间 200 余篇纹理表面缺陷机器视觉检测论文，对纹理表面缺陷机器视觉检测研究进展进行了及时、全面的调查。本文回顾了纹理表面缺陷检测的发展历史和最新研究进展，原则上将纹理表面缺陷机器视觉检测方法分为传统方法与深度学习方法，并对二者进行了深层次研究分析，特别是深度学习方法。本文对近期出现的几种纹理表面缺陷机器视觉检测方法主题进行总结的同时，也对这些主题的研究进展进行了综述。最后，我们对未来的研究趋势进行了展望，以期为后续研究提供指导和启示。

关键词：纹理；缺陷检测；机器视觉；机器学习；深度学习

中图分类号：TP399

Review of machine vision detection methods for texture surface defects

ZHU He¹, YANG Hua¹, YIN Zhouping¹

(1. School of Mechanical Science and Engineering, State Key Laboratory of Digital Manufacturing Equipment and Technology, Huazhong University of Science and Technology, Wuhan 430000, China)

Abstract: Texture surface defect detection is meaningful and challenging in the field of machine vision. The history of texture surface defect detection can be traced back to the mid to late 20th century. Moreover, in recent years, with the flourishing development of deep learning technology, texture surface defect detection technology had a big leap. However, so far, there are still few surveys and overviews about texture surface defect detection. Under such a background, we comprehensively reviewed more than 200 papers about texture surface defect detection by machine vision from 2017 to 2021 and made a timely and comprehensive investigation on the research progress of texture surface defect detection by machine vision. This paper reviews the development history and latest research progress of texture surface defect detection. In principle, the methods of texture surface defect detection by machine vision are divided into the traditional method and the deep learning method. And they were studied and analyzed deeply, especially the deep learning method. This paper summarizes several methods of texture surface defect detection by machine vision appearing recently and reviews the research progress of these themes. Finally, we introduced the future research trends to provide enlightenment for further studies.

Key words: Texture; Defect detecting; Machine vision; Machine learning; Deep learning

在工业制造领域，使用者和生产企业对产品质量需求越来越高，除了要求较高的功能品质和性能

品质之外，对产品外观品质的要求也在逐步提高。特别在服装、箱包等纺织领域内，用户对于产品外观品质的重视程度甚至大于其功能品质。如果这类产品存在脏污、变形等表面缺陷，导致产品美观度大打折扣的同时，其价值也将备受影响。

表面缺陷检测广泛应用于电子 3C、汽车、化工、

基金项目：国家自然科学基金项目（51875228）、国家重点研发计划（2020YFA0405700）、佛山市产业领域科技攻关专项（2020001006509）
作者简介：朱贺(1997-)，硕士研究生，研究方向为高速机器视觉、基于机器视觉的纹理表面缺陷检测，(zhuhe@hust.edu.cn)；
***通信作者：**杨华，教授，博士生导师，(huayang@hust.edu.cn)

轻工等行业,因自然物体表面多存在规则或者不规则的纹理背景,表面缺陷检测的一个主流研究方向为纹理表面缺陷检测。自 20 世纪开始,纹理表面缺陷检测大致经历了三个阶段:人工目视检测、光学传感器检测、机器视觉检测。本文将叙述纹理表面缺陷机器视觉检测方法的最新研究进展,并主要叙述以深度学习方法为主的纹理表面缺陷视觉检测算法研究成果。

本文其余部分组织如下:在第 1 章给出一个总体概述,包括纹理表面缺陷视觉检测的发展历史简述,以及现有纹理表面缺陷视觉检测方法分类。传统方法与深度学习方法分别在第 2 章与第 3 章中进行详细讨论。在第 4 章中探讨新兴的纹理表面缺陷检测研究方向,在第 5 章中进行对未来研究的展望,在第 6 章进行总结结束整篇综述。

1 概述

在本章节将简要概述纹理表面缺陷检测方法的研究现状,在 1.1 小节中简要介绍纹理与缺陷的定义;在 1.2 小节中简要介绍纹理表面缺陷机器视觉检测的发展历史,在 1.3 小节中介绍将纹理表面缺陷机器视觉检测方法分类原则,在 1.4 小节中介绍缺陷检测方法性能好坏评价标准。

1.1 定义

自然表面通常表现出一些重复的强度变化或图案,通常被称为纹理^[1]。从结构的角度来看,纹理产生于像素的空间变化,并与一系列具有一定随机性的重复模式的自然现象有关,纹理通常用它们的规则程度来描述,从规则纹理到随机纹理^[2],有研究将纹理分为 57 类^[3]。纹理在自然图像中普遍存在,为图像分割、图像检索和纹理形状等各种图像分析应用提供了重要视觉线索^[4]。

缺陷在纹理表面的表现形式为破坏纹理规则表达的现象,如图 1 所示,对缺陷的检测以有无缺陷判别、缺陷定位、缺陷分割、缺陷分类共四步组成,根据应用需求不同,缺陷检测需要进行到的程度也不同,其中最重要的是缺陷定位,多数方法也均以定位缺陷位置为缺陷检测结果,在实际中根据需求决定是否进行缺陷分割与缺陷分类。

1.2 演变史

纹理表面缺陷视觉检测方法发展至今可分为传统方法与深度学习方法两大类。在深度学习兴起之前,传统学习方法是该领域的研究主流,至今很多经典方法仍用于工业制造检测领域一线。早期的方法综述^[5-8]将传统方法进行了详细划分,大致可分为

统计方法、结构方法、滤波方法与基于模型方法。随着纹理表面视觉检测方法研究的不断深入,统计方法中的直方图操作等逐渐被更高级的诸如全局特征等方法替代、结构方法中的形态学操作等方法也因为方法更替,已不单独作为检测方法使用,目前在检测方法后处理中有部分应用。随着机器学习方法的不断研究,目前基于 SVM 强分类器、聚类、随机森林等基于传统机器学习的缺陷检测方法也逐步得到研究者的认可。

深度学习最早可追溯到 1943 年 McCulloch^[9]提出的 M-P 结构,到后来的感知机模型^[10],并突破于 1974 年 Rumelhart^[11]提出了反向传播算法 BP(backpropagation algorithm)的概念,2012 年 AlexNet^[12]在 ImageNet 竞赛中的表现将深度学习图像处理方法正式引入大家的视野中。自此之后基于深度学习的纹理表面视觉检测方法逐步兴起,从最开始的基于卷积神经网络 CNN(convolutional neural networks)方法,到基于目标检测模型、基于语义分割模型,缺陷检测精度不断提高,但监督学习方法需要在模型训练过程中提供近似相等的正负例样本才会达到较好的训练效果,在工业应用中,缺陷样本出现频率过低,导致基于监督模型的方法较难应用于工业领域,同时使得无监督学习方法、迁移学习方法的研究进程得以大大加快。

纹理表面缺陷视觉检测方法从最初的统计方法与结构方法发展至深度学习方法,无论从算法复杂度还是从缺陷检测精度,都有较大提升。目前,由于深度学习的优异性能,基于深度学习的方法已经成为纹理表面缺陷机器视觉检测方法研究领域的热点,同时由于工业制造领域缺陷样本不足以支撑模型训练,如何实现少样本训练缺陷检测模型,已经成为纹理表面缺陷视觉检测领域棘手难题。

1.3 分类方法

根据框架不同,可将现有纹理表面缺陷视觉检测方法分为传统方法与深度学习方法两种。在传统深度学习方法中,由于基于直方图方法、边缘检测方法、形态学方法等传统方法需要复杂、针对性强的算法设计工作,近年相关方向研究已逐渐减少,同时传统机器学习方法用其卓越的检测性能证明了其强大,所以将传统方法分类为:图像结构方法、频域分析方法与传统机器学习方法,并基于此三大类进一步细分。

深度学习根据其训练所需样本要求,分类为:监督学习方法、弱监督学习方法、无监督学习




图 1 纹理表面缺陷示例^{[8][75][154][217]}

方法、迁移学习方法与主动学习方法。其中，监督学习方法根据其所用网络特性可细分为：基于传统 CNN 方法、基于目标检测方法与基于语义分割方法；基于无监督学习方法可细分为：无监督样本训练方法、仿真缺陷样本训练方法，如图 2 所示。

纹理表面缺陷机器视觉检测方法的传统方法中以传统机器学习方法为研究重点，其方法精度低于深度学习方法，算法复杂度低，可嵌入性较强，在工业领域的小型设备上应用广泛。深度学习方法中以弱监督学习方法与无监督学习方法为研究重点，其精度高于传统方法，但因其黑箱性与高配置设备需求性，目前在工业领域应用少于传统方法。

1.4 评价指标

评价缺陷检测方法性能优劣的方式有很多，通常使用目标检测领域与语义分割领域常用指标进行评价，如准确率 Accuracy、综合评价指标 F1、交并比 IoU。下式中 TP 等符号代表意义如表 1 所示。

表 1 分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP	FN
反例	FP	TN

准确率 Accuracy 与像素准确率 PA(pixel accuracy)在缺陷检测领域是等价的，即缺陷与背景检测正确的像素点数与所有像素点数之比。

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \quad (1)$$

$$PA = \frac{TP + TN}{TP + FP + TN + FN} \quad (2)$$

查准率 Precision、召回率 Recall、正阳率 TPR 与假阳率 FPR，以上几个评价指标通常不用于评价缺陷检测方法表现好坏，有少数方法^[13]使用 FPR 值代表缺陷过检指标。

$$Precision = \frac{TP}{TP + FP} \quad (3)$$

$$Recall = \frac{TP}{TP + FN} \quad (4)$$

$$TPR = \frac{TP}{TP + FN} \quad (5)$$

$$FPR = \frac{FP}{TN + FP} \quad (6)$$

综合评价 F-measure 是评价分类模型好坏的关键指标，其最常用表现形式为 F1 指标，即 β 值为 1 时，代入式(7)的表现形式。

$$F - measure = \frac{(1 + \beta^2) \cdot Precision \cdot Recall}{\beta^2 \cdot (Precision + Recall)} \quad (7)$$

$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} \quad (8)$$

交并比 IoU(intersection over union)与 F1 指标均是较为苛刻的评价指标，可以更好反应缺陷检测方法在数据集上表现。其中， B_d 是缺陷检出面积， B_{gt} 是缺陷标定真值，式(10)是式(9)的像素表达形式。

$$IoU = \frac{area(B_d \cap B_{gt})}{area(B_d \cup B_{gt})} \quad (9)$$

$$IoU = \frac{TP}{TP + FP + FN} \quad (10)$$

受试者工作特征曲线下面积为 AUC(area under curve)；平均精度 AP(average precision)定义为缺陷的 P-R(precision-recall)曲线下面积，具体计算方法根据采点不同略有不同；平均精度均值 mAP(mean average precision)为多分类问题时所有类别 AP 值均值，在缺陷检测领域 AP 与 mAP 所反映效果相同。

$$AUC = \int_0^1 Tp(Fp) dFp \quad (11)$$

$$AP = \int_0^1 p(r) dr \quad (12)$$

$$mAP = mean(AP) \quad (13)$$

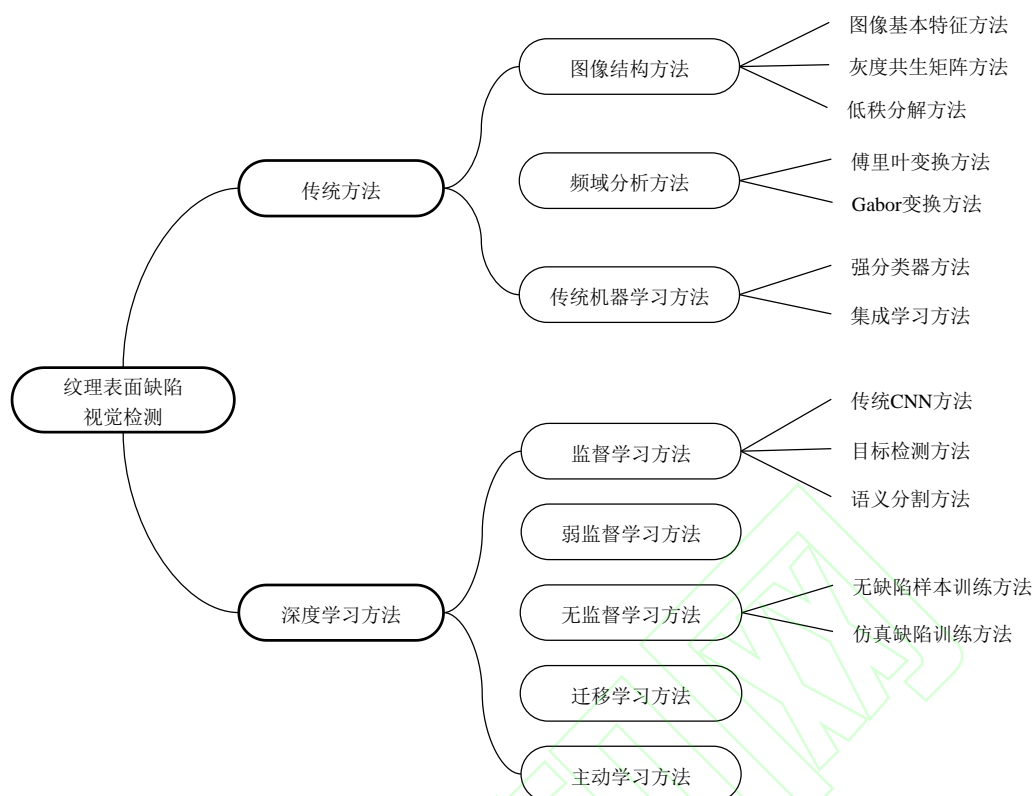


图 2 纹理表面缺陷视觉检测方法分类框架图

根据实验数据集的不同，对各方法表现进行了归纳总结，如表 2、表 3 所示，同时简述了各方法优缺点，如表 4 所示。

2 传统方法

正如 1.2 小节中所提到的传统分类方法所述，该章节主要介绍图像结构方法、频域分析方法与传统机器学习方法。

2.1 图像结构方法

在图像结构方法中，使用图像特征对图像直接进行缺陷检测是该类方法的特点，图像特征可以是纹理基元或纹理元素，以及整幅图像中基元的空间安排。该方法可分为：图像基本特征方法、灰度共生矩阵方法、低秩分解方法。

2.1.1 图像基本特征方法

使用图像的边缘特征或缺陷的固有特征、全局背景特征的显著性判别与纹理基元等进行缺陷检测均可以称为基于图像基本特征方法。

基于图像缺陷特有特征的方法通常从图像全局出发，统计全局与局部间的关系，使用特征信息对图像进行直接检测，获得缺陷检测结果^[14-16]。其中，Jiang 等人^[17]提出了一种基于 Sobel 算子与 patch 统计的缺陷检测算法，该方法应用于简单背景，抗背景噪声能力有限；Kumari 等人^[18]提出了一种基于

Sylvester 矩阵^[19]相似度度量的表面缺陷检测方法，根据输入图像与配准图像 Sylvester 矩阵秩情况等信息检测缺陷位置。

基于全局背景特征方法的一种是基于纹理特征均匀性，对突兀缺陷进行检测，有基于隶属度方法、显著性方法等^[20-22]，如 Zhang 等人^[23]将测试图像的隶属度矩阵转换为模糊隶属度矩阵，通过估计输入图像每个像素点的隶属度值得到缺陷检测结果；Qiu 等人^[24]使用多尺度显著性检测方法构建显著性图获得缺陷粗检测结果与粗定位的背景区域，再将缺陷图像分解为照度层与反射层。将反射层图像去噪，与缺陷粗检测结果同为依据，后处理获得缺陷精检测结果。该方法在 NEU 数据集^[25]上 F1 值为 86.7%。

基于纹理基元方法较为代表性的是 MVTec 公司提出的 texems 系列算法^{[26][27]}，两种方法可以在 MVTec 公司的商业软件 Halcon 上找到。除此之外 Jia 等人^[28]提出了一种基于纹理基元的织物表面缺陷检测方法，首先将输入图像进行晶格分割，提取晶格特征并判断晶格在特征上的距离，筛选出缺陷晶格，该方法在自建织物数据集进行了测试，缺陷检测精度 Accuracy 值 $\geq 96\%$ 。

图像基本特征方法使用图像特定背景与缺陷本身间的特征区别直接进行缺陷检测的方法，该类方法原理简单，复杂度低，同时方法具有针对性，多

针对特定纹理表面进行缺陷识别,缺陷检测效果在特定情况下、特定纹理表面上可达到较好效果。虽然存在局限性,但该类方法在工业场景中仍有较大应用前景。

2.1.2 灰度共生矩阵方法

灰度共生矩阵 GLCM(gray level co-occurrence matrix)是 1973 年 Haralick 等人^[29]提出的使用灰度图像空间相关性进行纹理描述的方法,是最著名和应用最广泛的纹理描述方法之一。该方法通过将二阶统计量被累积成一组二维矩阵,每个矩阵测量两个灰度级的空间依赖性,给定一个位移向量。纹理特征,如熵、对比度、逆差距与相关性等,可以基于灰度共生矩阵得到。提取上述特征与其他特征共同加工进行缺陷检测是目前 GLCM 的主流用法,将基于 GLCM 得到的特征直接用于缺陷检测,称为灰度共生矩阵方法。

Li 等人^[30]提出了一种基于多项二值算子与灰度共生矩阵 GLCM 的表面缺陷检测方法,该方法分为特征提取与缺陷检测两个方面,首先由多项二值描述子与 GLCM 提取无缺陷图像的多向纹理特征矩阵,其次根据特征矩阵的相似性确定检测阈值,再对输入图像提取特征矩阵,由预先确定的检测阈值检测缺陷;Tiemtud 等人^[31]提出了一种基于高斯增益非广度熵的芒果表面缺陷检测方法,首先提取输入图像的灰度共生矩阵特征,再对灰度共生矩阵每个小窗口(窗口大小 3×3 至 9×9)子域计算结合高斯增益的非广度熵^[32],对计算出的熵值拟合高斯分布,处于分布边缘的子域被认为是缺陷,该算法在自建芒果表面缺陷数据集进行测试,表现出了一定的缺陷检测能力。

GLCM 是经典的纹理表达方法,除此之外灰度共生矩阵仍存在一些变种方法,如灰度依赖性矩阵 NGLDM(neighboring gray level dependence matrix)^[33]、灰度行程矩阵 GLRLM(gray-level run-length matrix),除直接使用 GLCM 进行缺陷检测外,基于 GLCM 所提取特征与其他特征输入传统机器学习分类器、或者神经网络等进行表面缺陷检测^{[34][35]},也是效果优异的 GLCM 应用方法。

2.1.3 低秩分解方法

使用低秩分解检测图像显著性的方法。如果输入的数据特征矩阵是由两种比较明显的数据组成,其中一部分具有稀疏性,另一部分具有低秩性,则该数据矩阵可通过凸优化分解出低秩部分与稀疏部分,通常低秩部分被认为是背景,稀疏部分代表显著性区域。将该思想引入到缺陷检测领域中,对待

检测图像特征矩阵分解,提取低秩部分为背景,稀疏部分为缺陷^[36-38],即低秩分解方法。

较为有代表性的是 Zhou 等人^[39]提出了一种基于双低秩分解的钢材表面缺陷检测算法,通过将图像特征矩阵分解为背景特征矩阵与前景特征矩阵,分别低秩分解两个矩阵,融合两者分解结果得到缺陷检测结果;Mo 等人^[40]假设织物图像背景与缺陷部分均为低秩部分,将输入图像特征矩阵分解为低秩无缺陷矩阵与低秩缺陷矩阵,进行缺陷检测,该方法在 HKBU 数据集^[41-43]、TILDA 数据集^[44]、TianChi 数据集^[45]、自建数据集进行了实验,其中 HKBU 数据集各类别缺陷检测 F1 指标分别为 69%、43%、56%,优于其对比的传统方法。

低秩分解方法在近几年被应用于纹理表面缺陷检测,该类方法由实验结果可以看出,纹理背景不同,其方法效果不同^{[37][40]},规则纹理背景其缺陷检测效果较好,非规则纹理背景下缺陷检测效果欠佳。低秩分解方法是重要方法,分离背景与缺陷的思想是该类方法核心,其思想在提升该类方法的同时,也对如基于语义分割等其他检测方法带来了启迪。

2.2 频域分析方法

在图像处理领域中,频域变换会使得高频与低频信息分离,在空间域中的卷积运算会转换为乘法。频域中适用的变换也会使某些纹理特征更加凸显与可分,基于频域分析的表面缺陷检测同样是本领域研究热点,本小节将其细分为:傅里叶变换方法与 Gabor 变换方法。

2.2.1 傅里叶变换方法

傅里叶变换 Fourier 是由傅里叶级数推导出来的。使用傅里叶变换将图像空间域转变到频域分析是常用的转换方式,早期基于 Fourier 的检测方法以提取频域纹理特征进行缺陷检测为主^[46-48],近期出现了傅里叶变换与四元数图像表达相结合的缺陷检测方式,达到了较好的检测效果。

Di 等人^[49]提出了一种基于光照矫正与二维分数阶傅里叶变换 2D FRFT (2D fractional fourier transform)的表面缺陷检测方法,该方法使用多尺度侧窗盒滤波 MS-BOX(multi-scale side window box)^[50]提取图像光照分量并使用构建的二维伽马校正函数对图像进行全局角度光照矫正,并将图像转换为每个像素由颜色、强度和边缘特征组成的四元数表示。使用 2D FRFT 获得四元数图像的显著性矩阵,处理后得到缺陷检测结果,在自建数据集上缺陷检测效果优于轻量化网络方法 Mobile-Unet^[51];Liu 等人^[52]通过四元数矩阵将待检测图像合成多通

道重构图像,使用超复数傅里叶变换转换四元数图像到频域进行调谐,用局部高斯滤波器平滑振幅谱峰值,通过逆超复数傅里叶变换获得显著性图像即为缺陷检测结果,如图3所示。

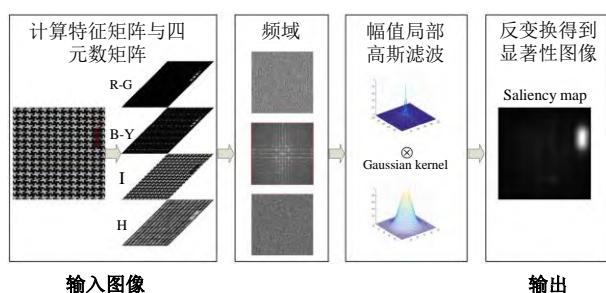


图3 傅里叶变换方法^[52]

傅里叶变换方法是经典的频域分析手段,其目的是通过频域表征分离难区分的特征用于表面缺陷检测,通常将其作为检测方法中转换模块使用^[49],使得问题简化。

2.2.2 Gabor 变换方法

Gabor 变换是短时 Fourier 变换中当窗函数设置为高斯函数时的一种特殊情况,可以将 Gabor 变换理解为是对图像进行卷积操作, Gabor 滤波器尝试在空间域和频域中进行最优联合定位^[53]。使用 Gabor 变换前,如何确定 Gabor 滤波器参数以获得最优情况,是首要需解决问题。

Li 等人^[54]基于 Gabor 滤波器与 Radon 变换提出了一种缺陷方向投影方法用于表面缺陷检测,该方法首先使用 Gabor 滤波器对输入图像进行滤波,再使用硬阈值分割图像,将分割二值图用 Radon 变换投影,选择缺陷值最大的通道作为 Gabor 滤波器最优通道检测缺陷;Sulistyaningrum 等人^[55]使用 Gabor 滤波器进行裂缝缺陷分割,结合形态学方法进一步处理分割结果,并将裂缝区域根据椭圆模型求解尺寸;Zhang 等人^[56]使用量子粒子群优化算法^[57]优化得到 Gabor 滤波器参数,对 Gabor 滤波器处理过的输入图像提取特征,根据孤立森林算法^[58]分离得到缺陷检测结果。

Gabor 变换方法提取出的纹理特征考虑了空间域与频域两者,是比 Fourier 变换考虑的更加全面的频域信息使用方法,如何确定 Gabor 滤波器参数是首先要考虑的问题,其达到的缺陷检测效果与参数选择也密切相关。与 GLCM 方法相同,常用 Gabor 变换提取特征该与分类器等方法相结合进行缺陷检测^{[36][39][53]}, Gabor 变换方法主要适用于规则纹理背景中或其他特定情况下的表面缺陷识别。

2.3 传统机器学习方法

机器学习作为人工智能领域的研究热门,在各个任务应用上均表现出优异的应用效果。将机器学习应用到纹理表面缺陷视觉检测领域同样达到了令人满意的效果。机器学习可分为传统机器学习与深度学习两个研究领域,基于传统机器学习的纹理表面缺陷视觉检测方法可细分为:基于强分类器方法、基于集成学习方法。

2.3.1 强分类器方法

传统机器学习研究领域一个主要任务即为分类任务,分类器、集成学习均为分类任务的一种实现方式。基于强分类器方法特指使用基于监督学习的强分类器模型,如支持向量机 SVM(support vector machines)的纹理表面缺陷视觉检测方法。

Zhou 等人^[34]提出了一种名为 WR-IFOA-SVM 的钢丝绳表面缺陷检测方法,WR-IFOA-SVM 使用同态滤波对图像进行预处理,消除因光照造成的缺陷识别影响,再提取由均匀模式处理过的 u-LBP 特征与基于 GLCM 的图像特征,由 SVM 得到缺陷检测结果,如图4所示;Gao 等人^[35]提出了一种基于 SVM 的路面缺陷检测方法,首先根据输入图像的灰度共生矩阵计算熵特征,根据熵特征初步分割背景与缺陷区域,再提取面积、周长、圆度、矩形体、宽高比、连通域特征、投影特征、分型特征使用 SVM 进行缺陷检测得到缺陷检测结果;Song 等人^[59]提出了一种基于多约束和改进纹理特征的显著性缺陷检测算法,其使用基于光谱聚类的超像素分割算法对输入图像进行超像素重构,由 SVM 预测结果,将得到的标记结果与提出的多约束策略结合得到缺陷检测结果。

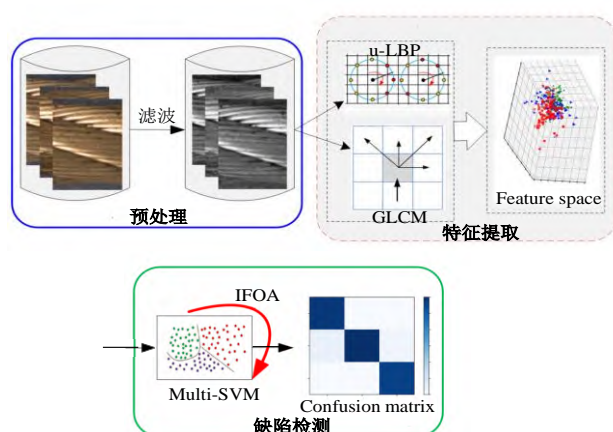


图4 基于 SVM 缺陷检测方法^[35]

除了 SVM 分类器外,还有一些基于其他强分类器的缺陷检测方法,如 Mentouri 等人^[60]提出了一种基于多尺度二值化统计图像特征与 K 最近邻方法 KNN(k-nearest neighbor algorithm)的钢板表面缺陷

检测方法,在 NEU 数据集上 Accuracy 值达到 99.6%;Yue 等人^[61]提出了一种基于黎曼流形与 Fisher 分类器的羽毛缺陷检测方法;Essa 等人^[62]提出了一种基于极限学习器 ELM (extreme learning machine)的表面缺陷检测方法,在 TILDA 数据集进行了测试,该方法缺陷检测 Accuracy 值在 98.07%。

基于分类器方法因其可靠的检测效果、异于深度学习黑盒特型的高度可解释性,以及适中的模型复杂度,该方法是目前传统方法中应用最为广泛的一种缺陷检测方法。

2.3.2 集成学习方法

集成学习是以多个弱分类器为基础,组合生成强分类器的一种分类方法,以 Bagging 策略与 Boosting 策略为主,其表现出与强分类器如 SVM 相近甚至更强的分类能力,目前应用较为广泛的是随机森林、优化的分布式梯度提升库 XGBoost(extreme gradient boosting)^[63]等,基于集成学习的缺陷检测方法性能同样优异。

Jawahar 等人^[64]提出了一种基于随机森林的表面缺陷检测方法,首先提取 GLCM 特征、不变矩 Hu 特征、HSV 颜色特征,再将提出的特征驶入随机森林得到缺陷检测结果;Chaudhari^[65]提取 GLCM 特征、Gabor 滤波特征、HOG 特征,使用随机森林进行缺陷检测;Chun 等人^[66]通过提取基于像素值的特征(局域灰度均值等)、几何特征(周长等)训练 XGBoost 的变种方法轻量梯度提升决策树 LightGBM(light gradient boosting machine)^[67]进行缺陷检测,该方法在自建混凝土桥梁与路面数据集上 F1 指标达到 69%;Jawahar 等人^[68]使用灰度共生矩阵提取并通过优化算法筛选特征,由随机森林分类器检测缺陷。

基于集成学习方法进行缺陷检测,虽然具有较强的缺陷检测能力,但集成学习方法出现过拟合现象更加频繁,其泛化能力要弱于其他传统机器学习方法,同时随机森林模型等集成学习方法具有一定的黑盒性质^[69],综上所述,该方法实际应用较少。

3 深度学习方法

如 1.2 小节中所提到的深度学习分类方法所述,该章节主要介绍监督学习方法、弱监督学习方法、无监督学习方法、迁移学习方法与主动学习方法。

3.1 监督学习方法

图像处理领域所用的深度学习网络框架多数基于卷积神经网络 CNN(convolutional neural networks),自 AlexNet 以来的深度学习方法多数从

监督学习开始发展,逐步发展到半监督、弱监督与无监督学习。在缺陷检测效果方面,监督学习方法检测效果最优。本小节将其细分为:基于传统 CNN 方法、基于目标检测方法、基于语义分割方法。

3.1.1 传统 CNN 方法

在深度学习方法引入纹理表面缺陷视觉检测领域初期,出现了一些基于 CNN 的缺陷检测方法,这些方法多数以数层卷积层为主体,进行特征提取及缺陷定位工作,作为初期的方法引入,其证明了将深度学习方法用于缺陷检测的可能性,同时该方法达到的效果通常优于传统方法。

早期基于深度学习方法的网络框架都相对简单^[70-75],如 Cha 等人^[76]提出了一种基于卷积神经网络的裂纹缺陷检测算法,使用 8 层网络结构,以 patch 为检测单位进行缺陷定位;Wang 等人^[77]提出了一个基于 11 层卷积神经网络的表面缺陷检测算法,如图 5 所示,该方法在 DAGM_2007^[78]数据集进行了测试,Accuracy 值达到了 99.8%;Staar 等人^[79]提出了一种基于欧几里得距离的三联合输入网络,通过衡量样本间的特征距离检测缺陷,该算法在 DAGM_2007 缺陷数据集进行了效果验证,不同情况下 AUC 值 $\geq 76\%$;Garg 等人^[80]提出了一种基于卷积神经网络的织物表面缺陷检测方法,该方法以 patch 为缺陷检测单位,对 patch 进行缺陷与非缺陷分类,在 TILDA 数据集上进行测试,缺陷检测效果优于基于传统方法的缺陷检测方法。




图 5 用于缺陷检测的传统 CNN 网络框架^[77]

基于传统 CNN 方法虽然所使用的网络结构及思想对比现阶段研究进展相对简单,但该类方法是将深度学习引入到缺陷检测领域的开始,证明了深度学习方法进行缺陷检测的可能性,对纹理表面缺陷机器视觉检测方法发展意义重大。

3.1.2 目标检测方法

目标检测(object detection)一直是深度学习领域研究重点,该领域方法以 RCNN(region-CNN)^[81]与 YOLO(you only look once)^{[82][83]}两个系列为发展主体,衍生出了 Faster RCNN^[84]、YOLO 等经典方法。目标检测方法的思想主要是由所要检测的目标产生一系列候选区域,根据产生的候选区域使用非

极大值抑制的方法定位合并出所需区域,即为检测结果。该思想契合缺陷检测初衷,大量基于深度学习的缺陷检测方法均属于基于目标检测方法。

Faster RCNN 网络、YOLO 系列网络、SSD 网络均可以直接应用于缺陷检测,所以基于该类网络的检测方法均有不错的效果^{[85][86]}。有研究者基于 Faster RCNN 进行缺陷检测,如 Zhou 等人^[87]在 Faster RCNN 基础上加入了可变形卷积^[88];Wei 等人^[89]减少了 Faster RCNN 网络框架中锚点数量的同时,也对网络结构进行了适当调整;Wei 等人^[90]在 Faster RCNN 基础上添加了视觉增益机制,通过视觉增益机制增加模型知觉的灵敏程度;Su 等人^[91]基于 Faster RCNN 构建了通道注意力网络与空间注意力网络连接的互补注意力网络,用于表面缺陷检测。基于 YOLO 系列网络与 SSD 网络同样很多,如 Jiang 等人^[92]在 YOLOv3 网络框架基础上,使用特征维度聚类将低级特征与高级信息结合进行表面缺陷检测;Li 等人^[93]在 SSD 框架基础上将浅层与深层特征融合进行缺陷检测,效果略优于 SSD 网络。

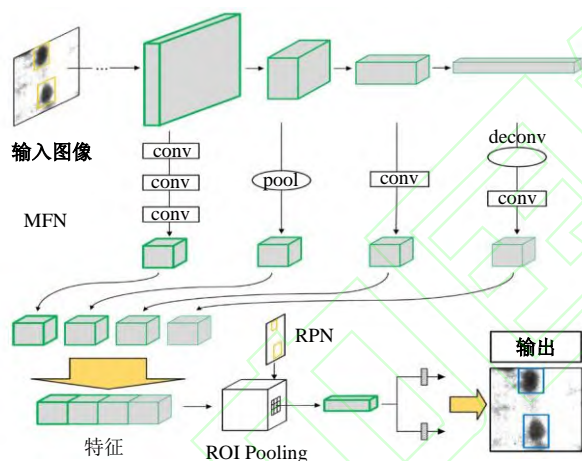


图 6 基于目标检测方法缺陷检测^[98]

有研究者未使用常用目标检测框架,其通过以目标检测方法思想为基础的方式构建纹理表面缺陷检测方法,如 Jun 等人^[94]使用 inction-v1 网络与用 LeNet-5 网络结合检测缺陷,该方法在 TILDA 缺陷数据集上 AUC 值达到了 87%;Wu 等人^[95]提出了一种由 Inception^[96]网络模块筛选滑窗 patch 的表面缺陷检测方法,该方法在 DAGM_2007 缺陷数据集上的 Accuracy 值达到了 98.6%;Lei 等人^[97]提出了一种基于合并和分裂策略的缺陷检测网络与自我比较驱动循环模型的表面缺陷检测方法;Liu 等人^[13]基于训练过的目标检测模型(如 VGG-16)中提取有用特征进行缺陷检测,在 TILDA 数据集上 Accuracy 值达到 93.9%;He 等人^[98]使用区域提议网络 RPN(region proposal network)生成可能的缺陷区域

ROI(regions of interest),并由检测器对 ROI 进行检测得到缺陷检测结果,如图 6 所示,在 NEU 数据集上该方法 mAP 值达到 82.3%。

基于目标检测方法表现出极强的缺陷检测能力,使得对缺陷检测精度要求略低的任务可直接套用目标检测算法网络框架,但深度学习方法对所搭载设备有较高要求,目前仅在配置极高的检测装备,如配备显卡 RTX2080Ti 等高算力设备上搭载。

3.1.3 语义分割方法

语义分割(semantic segmentation)与目标检测任务相同,是当今计算机视觉领域关键问题之一,将图像中的目标精确分类为语义标签,实现像素级分割精度是其任务所在,所研究的算法有基于区域的方法即基于 RCNN 方法,也有基于全卷积网络 FCN(fully convolutional network)^[99]方法。将语义分割方法引入到缺陷检测领域是该领域内的一大创举,本文主要介绍以 FCN 方法及其衍生网络为主的方法,该类方法也是语义分割领域主流方法,目前已经在缺陷检测领域达到了极佳的缺陷分割效果。

基于语义分割的缺陷检测方法最初以 FCN 为主要框架进行构建^{[100][101]},如 Zhang 等人^[102]提出的 CrackNet 的裂纹缺陷检测方法,该方法由 4 层宽高度相同,通道数不同的卷积层构成,输出像素级缺陷检测结果;Yu 等人^[103]使用两个全卷积 FCN 网络进行缺陷检测,第一个 FCN 网络负责粗推断缺陷位置,第二个 FCN 网络负责细化缺陷检测结果,该算法在 DAGM_2007 缺陷数据集进行了效果验证,其 Accuracy 值为 95.99%;Yang 等人^[104]在基于 FCN 网络检测缺陷基础上,推测裂缝拓扑形状、长度、宽度等信息,该方法实验的缺陷检测效果弱于 CrackNet^[103];Dung 等人^[105]使用仿 VGG16 的 FCN 检测方法在自建裂纹数据集上 F1 指标达到 89.3%,如图 7 所示。




图 7 基于 FCN 网络缺陷检测^[105]

基于 FCN 与 VGG16 网络,SegNet 网络^[106]被提出,有研究者将其引入到缺陷检测领域,如 Zou 等人^[107]提出了一种基于 SegNet 网络的裂纹缺陷检测方法 DeepCrack,该方法在 CrackTree260^[108]数据集进行训练,在自建数据集实验的缺陷检测 AP 值

>87%; Dong 等人^[109]提出了一种基于 SegNet 与焦点损失 FL(focal loss function)的隧道衬砌表面缺陷检测方法 FL-SegNet, 从自建数据集实验结果来看, 该方法缺陷检测效果较 SegNet 有较大提升; Ren 等人^[110]提出了一种基于 SegNet 网络的裂缝缺陷检测方法 CrackSegNet, 其在全卷积网络的基础上加入了空洞卷积、空洞金字塔及跳连模块, 在自建裂纹数据集上进行了实验, F1 指标达到 74.55%, 优于 U-net 网络 63.09%。

除 SegNet 网络外, U-net 网络^[111]因其优异的性能在各领域均有应用, 有研究者将 U-net 网络应用到缺陷检测中^[111-113], 如 Han 等人^[114]使用区域预测网络预测缺陷区域, 加入空洞卷积保持内部数据细节结构, 将可能存在缺陷的区域送入 U-net 分割网络中进行缺陷分割, 得到缺陷检测结果; Liu 等人^[115]提出了一种基于 U-net 与 ResNet 的 U-ResNet 网络结构方法用于 TFT-LCD 导电粒子缺陷检测; Zhou 等人^[116]提出了一种基于 U-net、PSN(parametric sigmoid norm)层^[117]的缺陷检测网络 PSD U-net。

基于语义分割方法所得到的缺陷检测结果与基于目标检测方法不同, 其输出为缺陷分割结果, 可以很方便得到像素级缺陷检测结果, 但与目标检测方法相比, 基于语义分割方法对标注依赖程度更高。

3.2 弱监督学习方法

在模型训练时通常存在样本标注不完全、样本标注错误、样本标注未达到像素级仅有图像级情况, 上述情况均属于弱监督学习范畴, 同时本文认同半监督学习属于弱监督学习的观点。为解决样本标注问题, 基于弱监督学习方法的缺陷检测方法兴起。

纹理表面缺陷检测弱监督学习方法表现形式多为使用图像级标注样本进行训练^[118-120], 其中, Chen 等人^[121]提出了一种使用图像级标注的基于注意力 CBAM(convolutional block attention module)^[122]的缺陷检测方法; Xu 等人^[123]提出了一种基于 CNN 与协同学习的弱监督表面缺陷检测算法, 该算法在 KolektorSDD 数据集^[124]上实验效果接近早期基于监督学习的缺陷检测方法; Gao 等人^[125]提出了一种基于自编码器的伪标签方法 PL(Pseudo-label)^[126]的弱监督钢表面缺陷识别方法, 该方法在 NEU 缺陷数据集上 Accuracy 值达到 90.7%, 同时表明已标记训练样本越多检测效果越好; Di 等人^[127]引入 SGAN(semi-supervised Generative Adversarial Networks)^[128]进行半监督学习, 利用分类网络对钢表面缺陷进行分类检测; Niu 等人^[129]提出了一种基于生成对抗网络 GAN(Generative adversarial

nets)^[130]的弱监督表面缺陷检测方法 DefectGAN, 其训练仅需要图像级标注样本, 在测试时产生像素级缺陷分割结果, 该方法在 DAGM_2007 数据集上缺陷检测效果与 SegNet 方法相近。

基于弱监督学习方法的缺陷检测方法目前可在一定程度上解决样本标注问题所带来的模型训练影响, 虽然弱监督学习方法缺陷检测精度通常低于监督学习方法, 但从缺陷检测效果对比看, 如表 2 所示, 现有弱监督学习方法检测精度已经与早期监督学习方法效果相近。

3.3 无监督学习方法

无监督学习是相对于监督学习的一种模型训练方式, 其特征是不需要标注样本进行训练, 代表性方法是聚类。在纹理表面缺陷视觉检测领域, 基于无监督学习的深度学习方法表现形式主要有两种: 无缺陷样本训练方法与仿真缺陷样本训练方法。

3.3.1 无缺陷样本训练方法

基于无缺陷样本训练方法是针对缺陷检测问题所提出的方法, 其主要思想是使用自编码器 AE(Auto encoder)或 GAN 的方式在无缺陷样本中提取纹理特征, 将输入图像重构无缺陷版本, 计算重构无缺陷图像与输入图像间的差分图, 得到缺陷检测结果^[131-139]。

该思想的代表方法是 AnoGAN^[140], 该方法以无缺陷样本作为训练样本进行无监督训练, 通过 GAN 学习正常样本分布隐空间, 当带缺陷样本输入网络时, 由隐空间变量重构无缺陷样本, 重构图像与输入图像的残差结合判别器输出即可定位缺陷, 如图 8 所示, AnoGAN 是第一个将 GAN 引入缺陷检测的方法, 并取得了极佳的效果。原研究者在 AnoGAN 基础上加入 Encoder 与 WGAN(Wasserstein GAN)^{[141][142]}提出了 f-AnoGAN^[143], 该方法在医学数据集上表现远高于基于 AE、AdvAE^[144]等方法; 后来 Akcay 等人^[145]提出了一种基于 GAN 的缺陷检测算法 GANomaly 算法, 使用条件生成对抗网络, 联合学习高维图像空间的生成和潜在空间学习无缺陷样本分布检测缺陷, 该方法在 MNIST 缺陷数据集^[146]、CIFAR 缺陷数据集^[147]、UBA 缺陷数据集^[148]进行了测试, 综合效果相比 AnoGAN 有大幅提升。

除基于 GAN 方法, 还有基于 AE 与 VAE 建立仿真缺陷数据集训练缺陷检测方法^[149-152], 其中 Wang 等人^[153]通过替换偏离无缺陷样本特征使用 VAE 生成无缺陷重构图像, 与输入图像对比后得到缺陷检测结果, 该方法在 MVTec^[154]数据集上的 Accuracy 值达到 85%, 高于 AnoGAN 的 55%; Tsai

等人^[155]在 CAE 模型上使用特征间距离确定缺陷位置,所提出算法在 Dagn_2007、MVTec 等数据集上缺陷检测效果优于 Deep-SVDD^[156]方法;Paul 等人^[157]提出了一种基于结构相似性感知损失 SSIM(structural similarity)^[158]卷积自编码器 AE 网络的表面缺陷检测算法,该方法以无缺陷样本特征聚类为思想对织物进行检测;Venkataramanan 等人^[159]通过综合注意力图与重构差分图生成缺陷检测结果,该方法在 MVTec 数据集 Accuracy 值达到 90%。

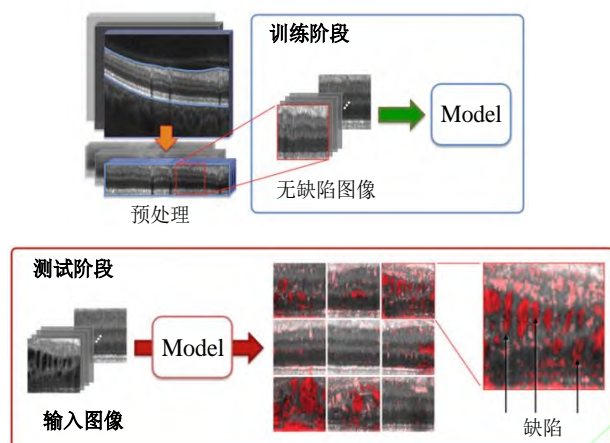


图 8 基于 GAN 的无监督缺陷检测 AnoGAN^[140]

基于无缺陷样本训练方法所能达到的缺陷检测精度远不及基于监督学习方法所能达到的效果,如表 2 所示,但由于其训练简单,无需缺陷样本并进行标注,越来越多人投入到无缺陷样本训练方法研究中,基于无缺陷样本训练方法已经成为纹理表面缺陷检测的研究核心,如何有效提升精度一直是该领域核心难题。

3.3.2 仿真缺陷样本训练方法

基于仿真缺陷训练方法是解决缺陷样本不足的一种方法,通过基于高斯模型、基于 GAN 的样本生成方式生成带标注的仿真缺陷样本,对缺陷检测模型进行训练,用于解决实际应用过程中缺陷样本不足问题^[160-165]。此外,还有研究者基于人工总结规律设计模板生成的仿真缺陷样本进行模型训练^[166-168]。

其中,较为有代表性的有:Wei 等人^[169]提出了一种基于缺陷样本仿真的表面缺陷检测算法,只需要每类别一张参考缺陷图像即可完成训练;Tsai 等人^[170]提出了一种基于 CycleGAN^[171]的仿真缺陷图像生成方法,将生成的仿真缺陷图像及对应的标签结果对 U-net 网络进行训练,如图 9 所示,所提出的缺陷检测算法在 DAGM_2007 数据集上测试达到 93.35% 的 Precision 值;Tang 等人^[172]提出了一种基于生成对抗网络 GAN 的合成图像数据增强方法,

利用生成的图像数据扩展训练数据集,提升了基于 Fast R-CNN、YOLOv3 模型的钢材表面缺陷检测效果,mAP 指标提升约 3%-5%;Saiz 等人^[173]提出了一种基于 StyleGAN2^[174]的金属制造零件缺陷样本生成方法,并应用于基于 DeepLabV3+^[175]与金字塔注意力网络缺陷识别网络,加入仿真缺陷样本后原缺陷检测方法在自建数据集 IoU 值提升了 2%-6%。

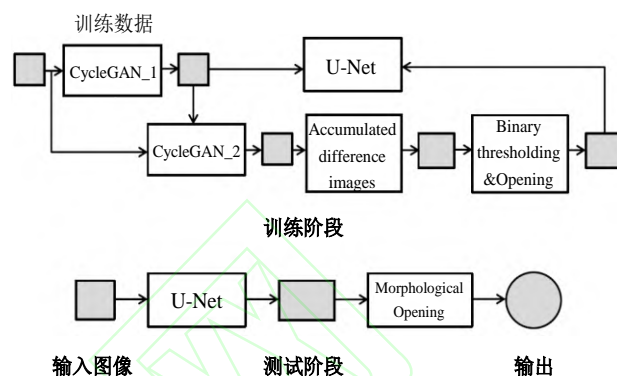


图 9 基于 CycleGAN 的缺陷检测^[170]

基于仿真缺陷训练方法的缺陷检测,在只有无缺陷样本的情况下生成带标注的缺陷样本,使用监督学习方法训练与检测。实验显示,加入仿真缺陷对缺陷检测精度有一定提升^{[172][173]},目前已有一定的研究者投入相关领域研究。如何使得仿真缺陷与真实缺陷相近,达到较好模型训练效果,是该方向研究重点。

3.4 迁移学习方法

监督学习方法效果较弱监督学习、无监督学习等方法提升巨大,但大量标注数据代价昂贵,在工业领域中多数情况下无法采集足够的缺陷样本进行训练。将相关领域中迁移标签数据或模型结构,完善提升任务的学习效果,是迁移学习的初衷及目的。基于迁移学习方法可以有效缓解因样本不足或样本标注代价过大导致的训练难题,因训练数据扩充,对原任务在多数情况下具有一定的效果提升,将迁移学习应用到缺陷检测领域主要为解决缺陷样本不足问题,目前已经有较多应用。基于迁移学习的缺陷检测方法通常在 ImageNet^[176]数据集下进行预训练^[177-183],此外,也有研究者在 VOC2007 数据集^[184]上预训练^[185]。

有研究者针对迁移学习特性对所提出基于迁移学习方法进行了实验,并证明了迁移学习的一些特性。Liong 等人^[186]使用一种基于 Mask R-CNN(mask region-convolutional neural networks)^[187]的视觉检测算法用于检测皮革表面缺陷。其训练所用的皮革图像数据仅有 84 张,但由于网络结构已经在 MS COCO(microsoft common objects in context

dataset)^[188]进行了共 150 多万张图像的广泛预训练, 在 500 张皮革图像测试集缺陷检测 Accuracy 值为 70.35% 的效果, 证明基于迁移学习的少样本纹理表面视觉检测算法具有一定的准确性; Badmos 等人^[189]对比了基于迁移学习的检测方法与未使用迁移学习方法缺陷检出效果, 其中基于迁移学习的检测方法在实验数据集上 F1 指标达到了 99%, 优于未使用迁移学习的检测方法; Damacharla 等人^[190]以 U-net 框架为基础采用迁移学习的方式进行训练, 其对比了使用 ImageNet 数据集进行预训练与不使用预训练的缺陷检测效果, 在自建数据集上, 基于迁移学习检测方法的缺陷检测 Accuracy 值优于未进行迁移学习的检测算法 26%; Aslam 等人^[191]提出了一种基于 EfficientNet^[192]与 DenseNet-201^[193]的深度学习框架, 对比包括皮肤图像数据集 HAM10000(human against machine with 10000 training images)^[194]、混凝土图像数据集 CODEBRIM(concrete defect bridge image)^[195]、目标识别数据集 ImageNet, 不同数据集预训练下的测试效果不同, 在 ImageNet 数据集上预训练相比于 HAM10000 数据集与 CODEBRIM 数据集预训练可达到更好效果, 更有助于表面缺陷识别, 证明了采用合适的预训练集对检测精度的提升同样有至关重要的影响。

基于迁移学习方法是缺陷样本不足问题的一种解决方案, 同时可以达到提升缺陷检测精度效果, 但应用迁移学习方法存在负迁移与负适配问题^[196]。迁移学习方法在使用的预训练数据集不同时存在效果差异^[191], 如何选择预训练数据集是迁移学习的核心问题, 由经验可得, 使用 ImageNet 数据集进行预训练在多数情况下可以达到较好缺陷检测效果, 同时应用场景不同, 最终检测效果不同。

3.5 主动学习方法

主动学习是一种人工与机器迭代标注的模型训练方法, 该方法在一定程度上可以减少样本标注代价, 但应用过程较为繁琐, 标注成本巨大。

Feng 等人^[197]提出了一种基于深度残差网络 Res-Net 的表面缺陷检测方法, 该方法使用结合人工选择标记重复训练的主动学习策略进行模型训练, 在自建缺陷数据集进行了缺陷检测效果测试, 在使用小于正常监督方法训练数量的标记样本进行训练后, 达到了 87.5% 的缺陷检测检测 Accuracy 值; Lv 等人^[198]提出了一种基于 YOLOv2^[199]的表面缺陷检测方法, 该方法使用迭代标注训练的主动学习策略进行模型训练, 在 NEU 数据集上进行了缺陷检测效果测试, 其 mAP 指标达到 64.5%。

基于主动学习方法的缺陷检测因训练过程较为繁琐, 实际应用较少。

4 新兴研究方向

纹理表面缺陷机器视觉检测领域发展至今, 出现了许多新兴的研究方向, 为今后的检测算法研究提供了研究思路。

4.1 轻量化网络方法

随着神经网络模型网络层数的不断增加, 网络复杂度的不断提升, 庞大的权值参数量使得普通设备运行网络模型变得十分困难, 将网络模型轻量化, 使其携带更少的参数, 可以在普通设备甚至移动端进行应用, 是网络轻量化任务所在。该任务以 SqueezeNet^[200]、MobileNet^[201]、ShuffleNet^[202]、Xception^[203]、EfficientNet^[192]模型为主发展出许多分支方法, 如何将缺陷检测网络轻量化也成为了目前热门研究方向。

Choi 等人^[204]基于深度可分离卷积提出了一种混凝土裂缝缺陷检测方法, 在自建裂纹缺陷数据集上缺陷检测效果与已有传统神经网络算法检测精度接近, 但参数量减少了 88 倍; Zhou 等人^[205]基于 EfficientNet 提出了一种缺陷检测方法, 总参数量 859 万; Lin 等人^[206]基于多尺度级联神经网络提出了一种基于 MobileNet-v2-dense 的表面缺陷检测方法, 该方法在 DAGM_2007 数据集 TPR 值达到 99.45%, 总参数量只有 212 万, 可以被集成在一般嵌入式设备上; Li 等人^[207]提出了一种基于 SSD 与 MobileNet 网络的缺陷检测算法, 在 DAGM_2007 数据集上 mAP 为 88.6%, 可应用于移动端设备; Jiang 等人^[51]提出了一种基于 MobileNetV2^[208]的 Mobile-Unet 表面缺陷检测方法, 参数总量约有 2298 万, 少于实验中所得到的 U-net 参数总量 11850 万; Wu 等人^[209]提出了一种基于混合卷积^[210]的轻量化缺陷检测方法, 加入了级联引导锚点模块等网络结构, 提升精度的同时也提升了效率; Huang 等人^[211]基于轻量化瓶颈层提出了一个轻量化表面缺陷检测方法, 在实验数据集上达到了与 MobileNetV2 相近的缺陷检测精度, 但参数量仅为 14 万。

缺陷检测网络轻量化目前是网络参数量与缺陷检测精度的平衡过程, 基于轻量化网络方法如何在减少网络参数量的同时尽可能提升缺陷检测精度, 是目前轻量化方法的核心研究难点。

表 2 DAGM_2007^[78]数据集测试效果

方法	方法描述	F1 指标	Accuracy 值	方法分类	发表年份
Yu 等 ^[103]	基于两阶段全卷积 FCN 网络的表面缺陷检测方法		95.99%	基于语义分割方法	2017
Wang 等 ^[77]	基于 11 层卷积神经网络的表面缺陷检测方法		99.8%	基于传统 CNN 方法	2018
Zhou 等 ^[178]	基于双 VGG16 网络的表面缺陷检测方法		99.49%	迁移学习方法	2019
Enshaei 等 ^[118]	使用粗略标记的弱监督 U-net 表面缺陷检测方法	79.33%	99.16%	弱监督学习方法	2020
Chen 等 ^[121]	基于注意力结构卷积神经网络的纹理表面缺陷检测方法	74.46%	99.85%	基于弱监督学习方法	2020
Zhang 等 ^[219]	基于弱监督学习的分类感知对象检测方法	65.8%	87.6%	基于知识蒸馏	2021
Tsai 等 ^[155]	基于改进的 CAE 模型的纹理表面缺陷检测方法		95%	基于无缺陷样本训练方法	2021

表 3 MVTec^[154]数据集测试效果

方法	方法描述	Accuracy 值	方法分类	发表年份
Schlegl 等 ^[140]	基于 GAN 的缺陷检测方法 AnoGAN	55%	基于无缺陷样本训练方法	2017
Bergmann 等 ^[157]	基于结构相似性感知损失 SSIM 卷积自编码器 AE 网络的表面缺陷检测方法	63%	基于无缺陷样本训练方法	2019
Venkataramanan 等 ^[159]	基于引导注意对抗变分自编码器 GAVGA 的缺陷检测方法(无监督)	78%	基于无缺陷样本训练方法	2020
Wang 等 ^[153]	基于 VQ-VAE 的表面缺陷检测方法	85%	基于无缺陷样本训练方法	2020
Tsai 等 ^[155]	基于改进 CAE 模型的纹理表面缺陷检测方法	91%	基于无缺陷样本训练方法	2021
Tellaeche 等 ^[151]	基于卷积自编码器与 OC-SVM 的纹理表面缺陷检测方法	92%	基于无缺陷样本训练方法	2021

表 4 纹理表面缺陷机器视觉检测方法优缺点比较

分类	方法	优点	缺点
传统方法	图像结构方法	方法原理简单	多数方法泛化能力差,仅适用于某一种特定情况下的缺陷检测
	频域分析方法	在空间域较难分离的特征在频域可分离性提升	频域分析方法对噪声敏感,多数情况下计算复杂,耗时较长
	传统机器学习方法	缺陷检测效果优于其他传统方法;与深度学习学习方法相比,可解释性强	在实际使用过程中,超参数对检测效果影响巨大
深度学习方法	监督学习方法	具有较高的缺陷检测精度,是目前缺陷检测效果最好的方法	需要大量标注正确的训练样本
	弱监督学习方法	基于存在标注问题样本进行训练,方法可达到较高精度	无过明显缺陷,属于监督学习与无监督学习方法的折中
	无监督学习方法	模型训练简单,仅使用无标记样本训练,不需要标注	缺陷检测精度相对监督学习方法较低
	迁移学习方法	使用其他领域数据训练模型,减少了对缺陷样本的需求	在不同预训练数据集下效果差异较大,存在负迁移、负适配问题
	主动学习方法	可以在样本标注较少情况下进行训练	模型训练需要人工与机器迭代,虽然减少了标注样本数量,但标注代价并没有过多下降

4.2 序列网络方法

序列模型(sequence models)是自然语言处理 NLP(Natural Language Processing)领域的核心模型,通过使用循环神经网络 RNN(recurrent neural network)对输入文字序列进行递归处理得到翻译/识别结果,较为经典的方法为长短期记忆人工神经网络 LSTM(long short-term memory),近期有人将相关思想引入到纹理表面缺陷检测中。

Zhang 等人^[212]提出了一种称为 CrackNet-R 的循环神经网络 RNN(recurrent neural network),用于沥青路面表面裂缝检测。该算法基于其提出的门控递归多层感知器,用于递归更新 CrackNet-R 的内部记忆, CrackNet-R 是一个两阶段处理算法,分为序列生成和序列建模,序列生成以找到最有可能形成裂纹的模式,序列建模预测序列为裂纹模式的概率,如图 10 所示,该方法在自建 500 张裂纹图像数据集进行了测试,与 CrackNet^[102]相比速度、精度均有一定提升;Zhao 等人^[213]通过视觉长短期记忆 VLSTM(visual long-short-term memory),即综合视觉感知特征、视觉短期记忆特征、视觉长期记忆特征进行缺陷检测,该方法在自建数据集进行了验证,综合缺陷检测性能优于 VGG 网络^[214]。

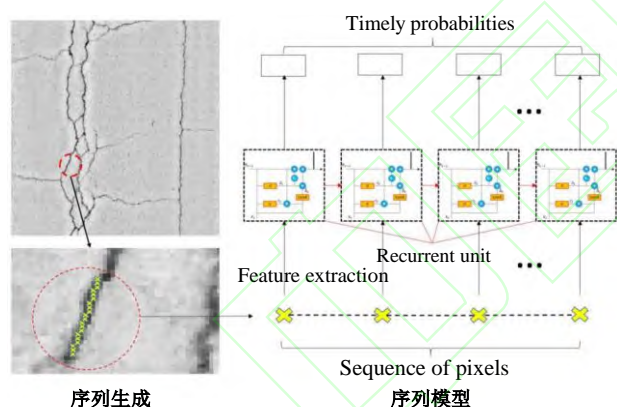


图 10 基于序列模型缺陷检测^[212]

基于序列模型的纹理表面缺陷机器视觉检测方法加强了对全局与局部特征的使用,并达到了较优的缺陷检测效果,自然语言处理思想的引入是对视觉领域的延伸,也为两领域更深入结合提供了思路。

4.3 其他方法

使得缺陷检测网络模型可以在嵌入式设备或其他普通设备上应用,一种方法是使用云服务器部署模式,由总服务器负责主要运算,子设备只需满足基本的搭载环境即可运行,如 Zhu 等人^[215]提出了一种基于改进 DenseNet 网络的表面缺陷检测方法,其具有较少的资源消耗及易于实现较高的缺陷检测效率。该方法搭载在基于云端部署的实时缺陷检测

系统上,在自建缺陷检测数据集进行了验证,11 种缺陷平均检测 Accuracy 值达到 83%。

纹理表面缺陷检测通常基于单张图像,但有时单张图像提取出的特征不足以精确表达特征,有研究基于视频流多帧信息进行缺陷检测,以提升检测效果,如 Chen 等人^[216]提出了一种基于朴素贝叶斯 Naïve Bayes 与卷积神经网络的裂缝缺陷检测方法 NB-CNN,该方法基于视频流对核电站表面进行裂纹缺陷检测。其中,所提出的卷积神经网络用于检测缺陷候选区域,用基于朴素贝叶斯的数据融合方案融合视频多帧图像信息去除误识别,在自建数据集上进行测试,其 FPPF(false positives per frame)指标 0.1 情况下 Accuracy 值达到 98.3%。

蕾丝等镂空织物的纹理表现形式为存在规则或不规则孔洞,由于使用或其他原因,织物表面会出现非刚性孔洞发生扩大、收缩等原有纹理损坏情况,即为非刚性变形缺陷。非刚性缺陷通常较难检测,有研究针对该类缺陷提出了检测方法,Xu 等人^[217]提出了一种针对织物表面变形缺陷的缺陷检测方法,该方法根据对比参考样本特征与输入样本特征差异,增强可能存在缺陷区域,容忍局部非刚性变形,定位织物变形缺陷位置,该方法在自建的工业花边织物非刚性缺陷检测实验中,Accuracy 值达到 96.9%,F1 指标达到 91.7%。

知识蒸馏是一种引入教师网络与学生网络的深度学习模型,属于网络压缩的范畴。使用大规模的教师网络以诱导小规模学生网络训练,实现知识迁移,其目的在于减少网络参数量,提升精度,该思想由 Hinton^[218]首次提出,有研究者将该思想应用于缺陷检测,如 Zhang 等人^[219]提出了一种弱监督学习的分类感知对象检测方法 CADN(category-aware object detection network)用于表面缺陷检测,该方法使用图像级标签进行模型训练,并使用知识蒸馏策略使得规模较轻的 CADN 网络模仿规模较大的 CADN 网络,以获得较好实时性与更高的缺陷检测精度,该方法在自建数据集与 DAGM_2007 缺陷数据集进行测试,在自建数据集 F1 指标学生网络为 95.6%,教师网络为 98.3%,在 DAGM_2007 数据集 F1 指标学生网络为 65.8%,教师网络为 69%,经知识蒸馏后的学生网络达到了与教师网络相差不多的缺陷检测效果。

5 未来展望

纹理表面缺陷视觉检测领域主要面向工业领域应用,目前存在的问题主要有以下三点:1)训练模型需要大量的缺陷样本,在实际应用时通常收集不

到足够的缺陷样本以支撑训练;2)网络模型轻量化问题,目前的深度学习网络模型主要基于强劲的计算处理设备,如何将其搭载在普通设备,甚至移动端设备同样是急需解决的难题;3)方法可解释性问题,在工业领域应用的重要前提为可靠,网络模型的黑盒特性使得其在工业中的应用在人们心中始终存在问号。如何解决上述问题,仍是纹理表面缺陷机器视觉检测领域研究重心。

1)缺陷样本稀缺是机器学习在工业领域应用一大难题,基于无缺陷样本训练方法、基于仿真缺陷训练方法是尝试解决该问题目前较为可靠的研究方向,也是目前的研究热点。随着小样本训练研究的推进,将元学习、基于度量学习等小样本方法思想引入缺陷检测领域或许是未来的研究方向。

2)网络轻量化,已经是计算机视觉领域一大研究热点,如何将深度学习方法应用于普通设备,大规模应用于工业现场,同样是工业领域面临的问题,已有的基于轻量化网络方法、基于云端部署的缺陷检测方法,均处于起步研究阶段,仍存在许多训练、精度、稳定性、泛化性等问题,在该研究方向同样有许多工作需要完成。

3)可解释性差是深度学习方法的一大硬伤,如何提升网络模型可解释性也是计算机视觉领域面临的一大棘手问题,在纹理表面缺陷机器视觉检测领域中较为折中的方法即传统方法与深度学习结合方法,但没有从网络模型根本出发解决问题,提升深度学习方法可解释性在未来需要研究者们努力。

在图像处理领域中,GAN的提出掀起了一股研究热潮,到至今为止很多视觉任务均能看到GAN的影子。现在又有将成熟的自然语言处理领域思想引入图像处理领域的趋势,如序列模型思想、Transformer思想等,已经有研究学者将Transformer^[220]引入到目标检测领域,并取得了不错的效果,未来在纹理表面缺陷机器视觉检测领域或许也可以看到相似思想的应用。

6 结论

本文对近几年纹理表面缺陷机器视觉检测方法进行了全面研究,对纹理表面缺陷机器视觉检测方法进行了通俗易懂的分类,分析了该领域内存在的问题,针对各个问题探讨了现有解决方法及其方法不足,分析了未来可能的研究方向,并总结了潜在的研究方向。希望通过本文,对纹理表面缺陷机器视觉检测领域研究学者提供详实有效参考的同时,促进该领域的进一步发展。

[参考文献]

- [1] Ojansivu V, Heikkilä J. Blur insensitive texture classification using local phase quantization[C]// Proceedings of the International conference on image and signal processing. Berlin, Heidelberg: Springer, 2008: 236-243.
- [2] AkL A, Yaacoub C, Donias M, et al. A survey of exemplar-based texture synthesis methods[J]. Computer Vision and Image Understanding, 2018, 172: 12-24.
- [3] Bormann R, Esslinger D, Hundsdoerfer D, et al. Texture characterization with semantic attributes: Database and algorithm[C]//Proceedings of the ISR 2016: 47st International Symposium on Robotics. Munich, Germany: VDE, 2016: 1-8.
- [4] Liu L, Fieguth P. Texture classification from random features[J]. IEEE transactions on pattern analysis and machine intelligence, 2012, 34(3): 574-586.
- [5] Xie X H. A review of recent advances in surface defect detection using texture analysis techniques[J]. ELCVIA: electronic letters on computer vision and image analysis, 2008: 1-22.
- [6] Ngan H Y T, Pang G K H, Yung N H C. Automated fabric defect detection-a review[J]. Image and vision computing, 2011, 29(7): 442-458.
- [7] Ngan H Y T, Pang G K H, Yung N H C. Automated fabric defect detection-a review[J]. Image and vision computing, 2011, 29(7): 442-458.
- [8] Hsieh Y A, Tsai Y J. Machine learning for crack detection: review and model performance comparison[J]. Journal of Computing in Civil Engineering, 2020, 34(5): 04020038.
- [9] McCulloch W S, Pitts W. A logical calculus of the ideas immanent in nervous activity[J]. The bulletin of mathematical biophysics, 1943, 5(4): 115-133.
- [10] Mohamed A, Dahl G, Hinton G. Deep belief networks for phone recognition[C]//Proceedings of the Nips workshop on deep learning for speech recognition and related applications. Vancouver, Canada: NIPS, 2009, 1(9): 39.
- [11] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. Cognitive modeling, 1988, 5(3): 1.
- [12] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25: 1097-1105.
- [13] Liu Z F, Liu S L, Li C L, et al. Fabric defect detection based on multi-source feature fusion[J]. International Journal of Clothing Science and Technology, 2021.
- [14] Hu H B, Xu D J, Zheng X P, et al. Pit defect detection on steel shell end face based on machine vision[C]// Proceedings of the 2020 IEEE 4th Information Technology, Networking, Electronic and Automation Control Conference (ITNEC). Chongqing China: IEEE, 2020, 1: 898-902.
- [15] Safaei N, Smadi O, Masoud A, et al. An automatic image processing algorithm based on crack pixel density for pavement crack detection and classification[J]. International Journal of Pavement Research and Technology, 2021: 1-14.
- [16] Wang X M, Zhang Z K. On-line defect detection and classification of latex gloves[J]. Journal of Physics: Conference Series. IOP Publishing, 2020, 1575(1): 012103.
- [17] Jiang J L, Jin Z L, Wang B H, et al. A Sobel operator combined with patch statistics Algorithm for fabric defect detection[J]. KSII Transactions on Internet and Information Systems (TIIS), 2020, 14(2): 687-701.

- [18] Kumari R, Bandara G, Dissanayake M B. Sylvester matrix-based similarity estimation method for automation of defect detection in textile fabrics[J]. *Journal of Sensors*, 2021, 2021.
- [19] Winkler J R, Halawani H. The sylvester and béout resultant matrices for blind image deconvolution[J]. *Journal of Mathematical Imaging and Vision*, 2018, 60(8): 1284-1305.
- [20] Ben Gharsallah M, Ben Braiek E. A visual attention system based anisotropic diffusion method for an effective textile defect detection[J]. *The Journal of The Textile Institute*, 2020: 1-15.
- [21] Song L W, Li R Z, Chen S Q. Fabric defect detection based on membership degree of regions[J]. *IEEE Access*, 2020, 8: 48752-48760.
- [22] Zhang J W, Wang H Y, Tian Y, et al. An accurate fuzzy measure-based detection method for various types of defects on strip steel surfaces[J]. *Computers in Industry*, 2020, 122: 103231.
- [23] Zhang H L, Peng L, Yu S, et al. Detection of surface defects in ceramic tiles with complex texture[J]. *IEEE Access*, 2021, 9: 92788-92797.
- [24] Qiu Y H, Tang L X, Li B, et al. Uneven illumination surface defects inspection based on saliency detection and intrinsic image decomposition[J]. *IEEE Access*, 2020, 8: 190663-190676.
- [25] Yosinski, J.; Clune, J.; Bengio, Y.; Lipson, H. How transferable are features in deep neural networks?[J]. *Proceedings of the Advances in Neural Information Processing Systems*, 2014, 3320-3328.
- [26] Xie X H, Mirmehdi M. TEXEMS: Texture exemplars for defect detection on random textured surfaces[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2007, 29(8): 1454-1464.
- [27] Böttger T, Ulrich M. Real-time texture error detection on textured surfaces with compressed sensing[J]. *Pattern Recognition and Image Analysis*, 2016, 26(1): 88-94.
- [28] Jia L, Chen C, Xu S K, et al. Fabric defect inspection based on lattice segmentation and template statistics[J]. *Information Sciences*, 2020, 512: 964-984.
- [29] Haralick R M, Shanmugam K, Dinstein I H. Textural features for image classification[J]. *IEEE Transactions on systems, man, and cybernetics*, 1973 (6): 610-621.
- [30] Li F, Yuan L N, Zhang K, et al. A defect detection method for unpatterned fabric based on multidirectional binary patterns and the gray-level co-occurrence matrix[J]. *Textile Research Journal*, 2020, 90(7-8): 776-796.
- [31] Tiemtud K, Saprasert P, Tormo T, et al. Automatic defect detection for mango fruit using non-extensive entropy with gaussian gain[J]. *Thai Journal of Mathematics*, 2020: 339-349.
- [32] Susan S, Hanmandlu M. A non-extensive entropy feature and its application to texture classification[J]. *Neurocomputing*, 2013, 120: 214-225.
- [33] Sun C J, Wee W G. Neighboring gray level dependence matrix for texture classification[J]. *Computer Vision, Graphics, and Image Processing*, 1983, 23(3): 341-352.
- [34] Zhou P, Zhou G B, Li Y M, et al. A hybrid data-driven method for wire rope surface defect detection[J]. *IEEE Sensors Journal*, 2020, 20(15): 8297-8306.
- [35] Gao M X, Wang X, Zhu S L, et al. Detection and segmentation of cement concrete pavement pothole based on image processing technology[J]. *Mathematical Problems in Engineering*, 2020, 2020.
- [36] Ji X, Liang J Z, Di L, et al. Fabric defect detection via weighted low-rank decomposition and Laplacian regularization[J]. *Journal of Engineered Fibers and Fabrics*, 2020, 15: 1558925020957654.
- [37] Shi B S, Liang J Z, Di L, et al. Fabric defect detection via low-rank decomposition with gradient information and structured graph algorithm[J]. *Information Sciences*, 2021, 546: 608-626.
- [38] Liu G H, Li F. Fabric defect detection based on low-rank decomposition with structural constraints[J]. *The Visual Computer*, 2021: 1-15.
- [39] Zhou S Y, Wu S Q, Cui K T, et al. Double low-rank based matrix decomposition for surface defect segmentation of steel sheet[J]. *ISIJ International*, 2021: ISIJINT-2021-024.
- [40] Mo D M, Wong W K, Lai Z H, et al. Weighted double-low-rank decomposition with application to fabric defect detection[J]. *IEEE Transactions on Automation Science and Engineering*, 2020.
- [41] Ngan H Y T, Pang G K H, Yung S P, et al. Defect detection on patterned jacquard fabric[C]//*Proceedings of the 32nd Applied Imagery Pattern Recognition Workshop*. Washington DC USA: IEEE, 2003: 163-168.
- [42] Ngan H Y T, Pang G K H. Novel method for patterned fabric inspection using Bollinger bands[J]. *Optical Engineering*, 2006, 45(8): 087202.
- [43] Ngan H Y T, Pang G K H. Regularity analysis for patterned texture inspection[J]. *IEEE Transactions on automation science and engineering*, 2008, 6(1): 131-144.
- [44] Workgroup on Texture Analysis of DFG Tilda Textile Texture Database[DB/OL]. [2021-10-06] <http://lmb.informatik.unifreiburg.de/research/dfg-texture/tilde>
- [45] Tianchi Database Obtained From AI Challenge in Xuelang Manufacturing: Visual Computing Assisted Quality Inspection[DB/OL]. [2021-10-06] <https://tianchi.aliyun.com/competition/entrance/231666/introduction>
- [46] Ciamberlini C, Francini F, Longobardi G, et al. Weaving defect detection by Fourier imaging[J]. *Vision Systems: Applications*. International Society for Optics and Photonics, 1996, 2786: 9-18.
- [47] Wood E J. Applying Fourier and associated transforms to pattern characterization in textiles[J]. *Textile Research Journal*, 1990, 60(4): 212-220.
- [48] Chan C H, Pang G K H. Fabric defect detection by Fourier analysis[J]. *IEEE transactions on Industry Applications*, 2000, 36(5): 1267-1276.
- [49] Di L, Long H B, Liang J Z. Fabric defect detection based on illumination correction and visual salient features[J]. *Sensors*, 2020, 20(18): 5147.
- [50] Yin H, Gong Y H, Qiu G P. Side window filtering[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Los Angeles CA, United States: IEEE, 2019: 8758-8766.
- [51] Jing J F, Wang Z, Räsch M, et al. Mobile-Unet: An efficient convolutional neural network for fabric defect detection[J]. *Textile Research Journal*, 2020: 0040517520928604.
- [52] Liu G H, Zheng X T. Fabric defect detection based on information entropy and frequency domain saliency[J]. *The Visual Computer*, 2021, 37(3): 515-528.
- [53] Chen L, Zeng S, Gao Q S, et al. Adaptive gabor filtering for fabric defect inspection[J]. *Journal of Computers*, 2020, 31(2): 45-55.
- [54] Li Y H, Zhou X Y. Fabric defect detection with optimal gabor wavelet based on radon[C]//*Proceedings of the 2020 IEEE International Conference on Power, Intelligent Computing and Systems (ICPICS)*. Shenyang China: IEEE, 2020: 788-793.
- [55] Sulistyaningrum D R, Setiyono B, Anita J N, et al. Measurement of crack damage dimensions on asphalt road using gabor filter[J]. *Journal of Physics: Conference Series*. IOP Publishing, 2021, 1752(1): 012086.
- [56] Zhang J W, Li Y Y, Luo H C. Defect detection in textile fabrics with optimal gabor filter and brdps algorithm[J].

- Journal of Physics: Conference Series. IOP Publishing, 2020, 1651(1): 012073.
- [57] Sun J, Feng B, Xu W B. Particle swarm optimization with particles having quantum behavior[C]//Proceedings of the 2004 congress on evolutionary computation (IEEE Cat. No. 04TH8753). Trondheim Norway: IEEE, 2004, 1: 325-331.
- [58] Liu F T, Ting K M, Zhou Z H. Isolation forest[C]//Proceedings of the 2008 eighth IEEE international conference on data mining. Singapore: IEEE, 2008: 413-422.
- [59] Song G R, Song K C, Yan Y H. Saliency detection for strip steel surface defects using multiple constraints and improved texture features[J]. Optics and Lasers in Engineering, 2020, 128: 106000.
- [60] Mentouri Z, Moussaoui A, Boudjehem D, et al. Steel strip surface defect identification using multiresolution binarized image features[J]. Journal of Failure Analysis and Prevention, 2020, 20(6): 1917-1927.
- [61] Yue H W, Wang H T, Chen H Z, et al. Automatic detection of feather defects using Lie group and fuzzy Fisher criterion for shuttlecock production[J]. Mechanical Systems and Signal Processing, 2020, 141: 106690.
- [62] Essa E, Hossain M S, Tolba A S, et al. Toward cognitive support for automated defect detection[J]. Neural Computing and Applications, 2020, 32(9): 4325-4333.
- [63] Chen T Q, Guestrin C. Xgboost: A scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining. San Francisco, USA: ACM, 2016: 785-794.
- [64] Jawahar M, Anbarasi L J, Jasmine S G, et al. A machine learning-based multi-feature extraction method for leather defect classification[M]//Inventive Computation and Information Technologies. Springer, Singapore, 2021: 189-202.
- [65] Chaudhari C V. Steel surface defect detection using glcm, gabor wavelet, hog, and random forest classifier[J]. Turkish Journal of Computer and Mathematics Education (TURCOMAT), 2021, 12(12): 263-273.
- [66] Chun P, Izumi S, Yamane T. Automatic detection method of cracks from concrete surface imagery using two-step light gradient boosting machine[J]. Computer-Aided Civil and Infrastructure Engineering, 2021, 36(1): 61-72.
- [67] Ke G L, Meng Q, Finley T, et al. Lightgbm: A highly efficient gradient boosting decision tree[J]. Advances in neural information processing systems, 2017, 30: 3146-3154.
- [68] Jawahar M, Babu N K C, Vani K, et al. Vision based inspection system for leather surface defect detection using fast convergence particle swarm optimization ensemble classifier approach[J]. Multimedia Tools and Applications, 2021, 80(3): 4203-4235.
- [69] 杨晔民, 张慧军, 张小龙. 随机森林的可解释性可视分析方法研究[J]. 计算机工程与应用, 2021, 57(6): 168-175.
- Yang Y M, Zhang H M, Zhang X L. Research on interpretable visual analysis method of random forest[J]. Computer Engineering and Applications, 2021, 57(6): 168-175.
- [70] Tan Z Y, Ji Y, Fei Z W, et al. Image-based scratch detection by fuzzy clustering and morphological features[J]. Applied Sciences, 2020, 10(18): 6490.
- [71] Park J K, Kwon B K, Park J H, et al. Machine learning-based imaging system for surface defect inspection[J]. International Journal of Precision Engineering and Manufacturing-Green Technology, 2016, 3(3): 303-310.
- [72] Zhou P, Zhou G B, Li Y M, et al. Surface defect detection for wire ropes based on deep convolutional neural network[C]//Proceedings of the 2019 14th IEEE International Conference on Electronic Measurement & Instruments (ICEMI). Lille, France: IEEE, 2019: 855-860.
- [73] Huang X Y, Liu Z L, Zhang X Y, et al. Surface damage detection for steel wire ropes using deep learning and computer vision techniques[J]. Measurement, 2020, 161: 107843.
- [74] Xie L F, Xiang X, Xu H N, et al. Ffcnn: A deep neural network for surface defect detection of magnetic tile[J]. IEEE Transactions on Industrial Electronics, 2020, 68(4): 3506-3516.
- [75] Kumar M P, Ashok D. A multi-level colour thresholding based segmentation approach for improved identification of the defective region in leather surfaces[J]. Engineering Journal, 2020, 24(2): 101-108.
- [76] Cha Y J, Choi W, Büyükoztürk O. Deep learning-based crack damage detection using convolutional neural networks[J]. Computer-Aided Civil and Infrastructure Engineering, 2017, 32(5): 361-378.
- [77] Wang T, Chen Y, Qiao M N, et al. A fast and robust convolutional neural network-based defect detection model in product quality control[J]. The International Journal of Advanced Manufacturing Technology, 2018, 94(9): 3465-3471.
- [78] DAGM 2007 Datasets[DB/OL]. [2021-10-06]. <https://hci.iwr.uni-heidelberg.de/node/3616>.
- [79] Staar B, Lützen M, Freitag M. Anomaly detection with convolutional neural networks for industrial surface inspection[J]. Procedia CIRP, 2019, 79: 484-489.
- [80] Garg M, Dhiman G. Deep convolution neural network approach for defect inspection of textured surfaces[J]. Journal of the Institute of Electronics and Computer, 2020, 2(1): 28-38.
- [81] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//IEEE conference on computer vision and pattern recognition. Columbus USA: IEEE, 2014: 580-587.
- [82] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. America: IEEE, 2016: 779-788.
- [83] Redmon J, Farhadi A. YoloV3: an incremental improvement[EB/OL]. [2021-10-06]. <https://pjreddie.com/media/files/papers/YOLOv3.pdf>.
- [84] Ren S Q, He K M, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28: 91-99.
- [85] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. America: IEEE, 2016: 779-788.
- [86] Xie L F, Xiang X, Xu H N, et al. Ffcnn: A deep neural network for surface defect detection of magnetic tile[J]. IEEE Transactions on Industrial Electronics, 2020, 68(4): 3506-3516.
- [87] Zhou H, Jang B, Chen Y X, et al. Exploring faster RCNN for fabric defect detection[C]//Proceedings of the 2020 Third International Conference on Artificial Intelligence for Industries (AI4I). Xiamen China: IEEE, 2020: 52-55.
- [88] Dai J F, Qi H Z, Xiong Y W, et al. Deformable convolutional networks[C]//Proceedings of the IEEE international conference on computer vision. Italy: IEEE, 2017: 764-773.
- [89] Wei B, Hao K R, Tang X S, et al. Fabric defect detection based on faster RCNN[C]//Proceedings of the International conference on artificial intelligence on textile and apparel. Cham: ICATA, 2018: 45-51.

- [90] Wei B, Hao K R, Gao L, et al. Detecting textile micro-defects: A novel and efficient method based on visual gain mechanism[J]. *Information Sciences*, 2020, 541: 60-74.
- [91] Su B Y, Chen H Y, Chen P, et al. Deep learning-based solar-cell manufacturing defect detection with complementary attention network[J]. *IEEE Transactions on Industrial Informatics*, 2020, 17(6): 4084-4095.
- [92] Jing J F, Zhuo D, Zhang H H, et al. Fabric defect detection using the improved YOLOv3 model[J]. *Journal of Engineered Fibers and Fabrics*, 2020, 15: 1558925020908268.
- [93] Li C C, Cui G H, Zhang W W, et al. Defect detection in vehicle mirror nonplanar surfaces with multi-scale atrous single-shot detect mechanism[J]. *AIP Advances*, 2021, 11(7): 075202.
- [94] Jun X, Wang J G, Zhou J, et al. Fabric defect detection based on a deep convolutional neural network using a two-stage strategy[J]. *Textile Research Journal*, 2021, 91(1-2): 130-142.
- [95] Wu X J, Cao K, Gu X D. A surface defect detection based on convolutional neural network[C]//*Proceedings of the International Conference on Computer Vision Systems*. Cham: ICVS, 2017: 185-194.
- [96] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. Boston, USA: IEEE, 2015: 1-9.
- [97] Lei Jie, Gao X, Feng Z L, et al. Scale insensitive and focus driven mobile screen defect detection in industry[J]. *Neurocomputing*, 2018, 294: 72-81.
- [98] He Y, Song K C, Meng Q G, et al. An end-to-end steel surface defect detection approach via fusing multiple hierarchical features[J]. *IEEE Transactions on Instrumentation and Measurement*, 2019, 69(4): 1493-1504.
- [99] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. Boston USA: IEEE, 2015: 3431-3440.
- [100] Wang R, Guo Q, Lu S M, et al. Tire defect detection using fully convolutional network[J]. *IEEE Access*, 2019, 7: 43502-43510.
- [101] Wang S, Wu X, Zhang Y H, et al. A neural network ensemble method for effective crack segmentation using fully convolutional networks and multi-scale structured forests[J]. *Machine Vision and Applications*, 2020, 31(7): 1-18.
- [102] Zhang A, Wang K C P, Li Baoxin, et al. Automated pixel-level pavement crack detection on 3D asphalt surfaces using a deep-learning network[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2017, 32(10): 805-819.
- [103] Yu Z Y, Wu X J, Gu X D. Fully convolutional networks for surface defect inspection in industrial environment[C]//*International conference on computer vision systems*. Cham: ICVS, 2017: 417-426.
- [104] Yang X C, Li H, Yu Y T, et al. Automatic pixel - level crack detection and measurement using fully convolutional network[J]. *Computer - Aided Civil and Infrastructure Engineering*, 2018, 33(12): 1090-1109.
- [105] Dung C V, Anh L D. Autonomous concrete crack detection using deep fully convolutional neural network[J]. *Automation in Construction*, 2019, 99: 52-58.
- [106] badrinarayanan V, kendall A, cipolla R. Segnet: A deep convolutional encoder-decoder architecture for image segmentation[J]. *IEEE transactions on pattern analysis and machine intelligence*, 2017, 39(12): 2481-2495.
- [107] Zou Q, Zhang Z, Li Q Q, et al. Deepcrack: learning hierarchical convolutional features for crack detection[J]. *IEEE Transactions on Image Processing*, 2018, 28(3): 1498-1512.
- [108] Zou Q, Cao Y, Li Q Q, et al. CrackTree: Automatic crack detection from pavement images[J]. *Pattern Recognition Letters*, 2012, 33(3): 227-238.
- [109] Dong Y N, Wang J, Wang Z F, et al. A deep-learning-based multiple defect detection method for tunnel lining damages[J]. *IEEE Access*, 2019, 7: 182643-182657.
- [110] Ren Y P, Huang J S, Hong Z Y, et al. Image-based concrete crack detection in tunnels using deep fully convolutional networks[J]. *Construction and Building Materials*, 2020, 234: 117367.
- [111] Huang Y B, Qiu C Y, Yuan K. Surface defect saliency of magnetic tile[J]. *The Visual Computer*, 2020, 36(1): 85-96.
- [112] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//*Proceedings of the International Conference on Medical image computing and computer-assisted intervention*. Springer Cham: ICMCC, 2015: 234-241.
- [113] Jiang J B, Cao P, Lu Z C, et al. Surface defect detection for mobile phone back glass based on symmetric convolutional neural network deep learning[J]. *Applied Sciences*, 2020, 10(10): 3621.
- [114] Han H, Gao C Q, Zhao Y, et al. Polycrystalline silicon wafer defect segmentation based on deep convolutional neural networks[J]. *Pattern Recognition Letters*, 2020, 130: 234-241.
- [115] Liu E Y, Chen K P, Xiang Z Y, et al. Conductive particle detection via deep learning for ACF bonding in TFT-LCD manufacturing[J]. *Journal of Intelligent Manufacturing*, 2020, 31(4): 1037-1049.
- [116] Zhou G H, Sun H Y. Defect detection method for steel based on semantic segmentation[C]//*Proceedings of the 2020 IEEE 5th Information Technology and Mechatronics Engineering Conference (ITOEC)*. IEEE, 2020: 975-979.
- [117] Srivastava Y, Murali V, Dubey S R. Psnet: Parametric sigmoid norm based cnn for face recognition[C]//*Proceedings of the 2019 IEEE Conference on Information and Communication Technology*. Allahabad India: IEEE, 2019: 1-4.
- [118] Enshaei N, Ahmad S, Naderkhani F. Automated detection of textured-surface defects using UNet-based semantic segmentation network[C]//*Proceedings of the 2020 IEEE International Conference on Prognostics and Health Management (ICPHM)*. San Francisco USA: IEEE, 2020: 1-5.
- [119] Racki D, Tomazevic D, Skocaj D. A compact convolutional neural network for textured surface anomaly detection[C]//*Proceedings of the 2018 IEEE Winter Conference on Applications of Computer Vision (WACV)*. Nevada, USA: IEEE, 2018: 1331-1339.
- [120] Marino S, Beausery P, Smolarz A. Weakly-supervised learning approach for potato defects segmentation[J]. *Engineering Applications of Artificial Intelligence*, 2019, 85: 337-346.
- [121] Chen H Y, Hu Q D, Zhai B S, et al. A robust weakly supervised learning of deep Conv-Nets for surface defect inspection[J]. *Neural Computing and Applications*, 2020: 1-16.
- [122] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//*Proceedings of the European conference on computer vision (ECCV)*. Munich, Germany: IEEE, 2018: 3-19.
- [123] Xu L, Lv S, Deng Y, et al. A weakly supervised surface defect detection based on convolutional neural network[J].

- IEEE Access, 2020, 8: 42285-42296.
- [124] KolektorSDD Dataset[DB/OL]. [2021-10-06]. <http://www.vicos.si/Downloads/KolektorSDD>.
- [125] Gao Y P, Gao L, Li X Y, et al. A semi-supervised convolutional neural network-based method for steel surface defect recognition[J]. Robotics and Computer-Integrated Manufacturing, 2020, 61: 101825.
- [126] Lee D H. Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks[C]//Proceedings of the Workshop on challenges in representation learning. Atlanta GA USA: ICML, 2013, 3(2): 896.
- [127] Di H, Ke X, Peng Z, et al. Surface defect classification of steels with a new semi-supervised learning method[J]. Optics and Lasers in Engineering, 2019, 117: 40-48.
- [128] Odena A. Semi-supervised learning with generative adversarial networks[EB/OL]. [2021-10-06]. <https://arxiv.org/pdf/1606.01583.pdf%5D>.
- [129] Niu S, Lin H, Niu T, et al. DefectGAN: Weakly-supervised defect detection using generative adversarial network[C]//Proceedings of the 2019 IEEE 15th international conference on automation science and engineering (CASE). Jinan China: IEEE, 2019: 127-132.
- [130] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative Adversarial Nets[C]//Proceedings of the International Conference on Neural Information Processing Systems. Bangkok, Thailand: MIT Press, 2014.
- [131] Liu K, Li A M, Wen X, et al. Steel surface defect detection using GAN and one-class classifier[C]//Proceedings of the 2019 25th International Conference on Automation and Computing (ICAC). Umea Sweden: IEEE, 2019: 1-6.
- [132] Wei W, Deng D X, Zeng L, et al. Real-time implementation of fabric defect detection based on variational automatic encoder with structure similarity[J]. Journal of Real-Time Image Processing, 2021, 18(3): 807-823.
- [133] Hu G H, Huang J F, Wang Q H, et al. Unsupervised fabric defect detection based on a deep convolutional generative adversarial network[J]. Textile Research Journal, 2020, 90(3-4): 247-270.
- [134] Zhai W, Zhu J, Cao Y, et al. A generative adversarial network based framework for unsupervised visual surface inspection[C]//Proceedings of the 2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Calgary Canada: IEEE, 2018: 1283-1287.
- [135] Zhao Z X, Li B, Dong R, et al. A surface defect detection method based on positive samples[C]//Proceedings of the Pacific Rim International Conference on Artificial Intelligence. Springer Cham: PRICAI, 2018: 473-481.
- [136] Lai Y T K, Hu J S. A texture generation approach for detection of novel surface defects[C]//Proceedings of the 2018 IEEE International Conference on Systems, Man, and Cybernetics (SMC). Guangzhou China: IEEE, 2018: 4357-4362.
- [137] Haselmann M, Gruber D P, Tabatabai P. Anomaly detection using deep learning based image completion[C]//Proceedings of the 2018 17th IEEE International Conference on Machine Learning and Applications (ICMLA). Orlando FL USA: IEEE, 2018: 1237-1242.
- [138] Wang J C, Yi G D, Zhang S Y, et al. An unsupervised generative adversarial network-based method for defect inspection of texture surfaces[J]. Applied Sciences, 2021, 11(1): 283.
- [139] Liu W Q, Li R Z, Zheng M, et al. Towards visually explaining variational autoencoders[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle USA: IEEE, 2020: 8642-8651.
- [140] Schlegl T, Seeöck P, Waldstein S M, et al. Unsupervised anomaly detection with generative adversarial networks to guide marker discovery[C]//Proceedings of the International conference on information processing in medical imaging. Springer Cham: ICIPM, 2017: 146-157.
- [141] Arjovsky M, Bottou L. Towards principled methods for training generative adversarial networks[C]//Proceedings of the International Conference on Learning Representations (ICLR). Toulon France: IEEE, 2017: 1-17.
- [142] Arjovsky M, Chintala S, Bottou L. Wasserstein GAN[EB/OL]. [2021-10-06]. <https://arxiv.org/abs/1701.07875>.
- [143] Schlegl T, Seeöck P, Waldstein S M, et al. f-AnoGAN: Fast unsupervised anomaly detection with generative adversarial networks[J]. Medical image analysis, 2019, 54: 30-44.
- [144] Pathak D, Krahenbuhl P, Donahue J, et al. Context encoders: Feature learning by inpainting[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. USA: IEEE, 2016: 2536-2544.
- [145] Akcay S, Atapour-Abarghouei A, Breckon T P. Ganomaly: Semi-supervised anomaly detection via adversarial training[C]//Proceedings of the Asian conference on computer vision. Springer Cham: ACMV, 2018: 622-637.
- [146] Mnist handwritten digit database[DB/OL]. [2021-10-06]. <http://yann.lecun.com/exdb/mnist>.
- [147] Krizhevsky A, Hinton G. Learning multiple layers of features from tiny images[J]. Tech. rep., Citeseer, 2009.
- [148] Akcay S, Kundegorski M E, Willcocks C G, et al. Using deep convolutional neural network architectures for object classification and detection within x-ray baggage security imagery[J]. IEEE transactions on information forensics and security, 2018, 13(9): 2203-2215.
- [149] Mei S, Yang H, Yin Z P. An unsupervised-learning-based approach for automated defect inspection on textured surfaces[J]. IEEE Transactions on Instrumentation and Measurement, 2018, 67(6): 1266-1277.
- [150] Zhang H W, Liu S T, Ge Z Q, et al. Yarn-dyed shirt cut pieces defect detection using attention vector quantized-variational autoencoder[C]//Proceedings of the 2021 IEEE 10th Data Driven Control and Learning Systems Conference (DDCLS). Suzhou China: IEEE, 2021: 1356-1361.
- [151] Tellaeche I A, Campos A M Á, Pajares M G, et al. On combining convolutional autoencoders and support vector machines for fault detection in industrial textures[J]. Sensors, 2021, 21(10): 3339.
- [152] Yang H, Chen Y F, Song K Y, et al. Multiscale feature-clustering-based fully convolutional autoencoder for fast accurate visual inspection of texture surface defects[J]. IEEE Transactions on Automation Science and Engineering, 2019, 16(3): 1450-1467.
- [153] Wang L, Zhang D K, Guo J H, et al. Image anomaly detection using normal data only by latent space resampling[J]. Applied Sciences, 2020, 10(23): 8660.
- [154] Bergmann P, Fauser M, Sattlegger D, et al. MVTec AD--A comprehensive real-world dataset for unsupervised anomaly detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. USA: IEEE, 2019: 9592-9600.
- [155] Tsai D M, Jen P H. Autoencoder-based anomaly detection for surface defect inspection[J]. Advanced Engineering Informatics, 2021, 48: 101272.
- [156] Ruff L, Vandermeulen R A, Gornitz N, et al. Deep

- support vector data description for unsupervised and semi-supervised anomaly detection[C]//Proceedings of the ICML 2019 Workshop on Uncertainty and Robustness in Deep Learning, Long Beach CA USA: IEEE, 2019: 9-15.
- [157] Bergmann P, Löwe S, Fauser M, et al. Improving unsupervised defect segmentation by applying structural similarity to autoencoders[EB/OL]. [2021-10-06]. <https://arxiv.org/abs/1807.02011>.
- [158] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.
- [159] Venkataraman S, Peng K C, Singh R V, et al. Attention guided anomaly localization in images[C]//Proceedings of the European Conference on Computer Vision. Germany: ECCV, 2020: 485-503.
- [160] Yang H, Zhou Q Y, Song K Y, et al. An anomaly feature-editing-based adversarial network for texture defect visual inspection[J]. IEEE Transactions on Industrial Informatics, 2020, 17(3): 2220-2230.
- [161] Haselmann M, Gruber D. Supervised machine learning based surface inspection by synthesizing artificial defects[C]//Proceedings of the 2017 16th IEEE international conference on machine learning and applications (ICMLA). Cancun, Mexico: IEEE, 2017: 390-395.
- [162] Liu L Z, Cao D H, Wu Y B, et al. Defective samples simulation through adversarial training for automatic surface inspection[J]. Neurocomputing, 2019, 360: 230-245.
- [163] He Y, Song K C, Dong H W, et al. Semi-supervised defect classification of steel surface based on multi-training and generative adversarial network[J]. Optics and Lasers in Engineering, 2019, 122: 294-302.
- [164] Wu X J, Qiu L T, Gu X D, et al. Deep learning-based generic automatic surface defect inspection (ASDI) with pixelwise segmentation[J]. IEEE Transactions on Instrumentation and Measurement, 2020, 70: 1-10.
- [165] Wei T R, Cao D H, Jiang X R, et al. Defective samples simulation through neural style transfer for automatic surface defect segment[C]//Proceedings of the 2019 International Conference on Optical Instruments and Technology: Optoelectronic Measurement Technology and Systems. Beijing China: International Society for Optics and Photonics, 2020, 11439: 1143904.
- [166] Li C S, Huang Y J, Li H, et al. A weak supervision machine vision detection method based on artificial defect simulation[J]. Knowledge-Based Systems, 2020, 208: 106466.
- [167] Prappacher N, Bullmann M, Bohn G, et al. Defect detection on rolling element surface scans using neural image segmentation[J]. Applied Sciences, 2020, 10(9): 3290.
- [168] Wang Z, Jing J F. Pixel-wise fabric defect detection by CNNs without labeled training data[J]. IEEE Access, 2020, 8: 161317-161325.
- [169] Wei T R, Cao D H, Zheng C Y, et al. A simulation-based few samples learning method for surface defect segmentation[J]. Neurocomputing, 2020, 412: 461-476.
- [170] Tsai D M, Fan S K S, Chou Y H. Auto-annotated deep segmentation for surface defect detection[J]. IEEE Transactions on Instrumentation and Measurement, 2021.
- [171] Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks [C]//Proceedings of the The IEEE international conference on computer vision. Italy: IEEE, 2017: 2223-2232.
- [172] Tang R J, Mao K M. An improved GANs model for steel plate defect detection[J]. IOP Conference Series: Materials Science and Engineering. 2020, 790(1): 012110.
- [173] Saiz F A, Alfaro G, Barandiaran I, et al. Generative adversarial networks to improve the robustness of visual defect segmentation by semantic networks in manufacturing components[J]. Applied Sciences, 2021, 11(14): 6368.
- [174] Zhao S, Liu Z, Lin J, et al. Differentiable augmentation for data-efficient gan training[EB/OL]. [2021-10-06]. <https://arxiv.org/pdf/2006.10738.pdf>.
- [175] Chen L C, Zhu Y K, Papandreou G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European conference on computer vision (ECCV). Munich Germany: ECCV, 2018: 801-818.
- [176] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]//Proceedings of the 2009 IEEE conference on computer vision and pattern recognition. USA: IEEE, 2009: 248-255.
- [177] Yu Y J, Cao H, Yan X Y, et al. Defect identification of wind turbine blades based on defect semantic features with transfer feature extractor[J]. Neurocomputing, 2020, 376: 1-9.
- [178] Zhou F, Liu G H, Xu F, et al. A generic automated surface defect detection based on a bilinear model[J]. Applied Sciences, 2019, 9(15): 3159.
- [179] Radford A, Metz L, Chintala S. Unsupervised representation learning with deep convolutional generative adversarial networks[DB/OL]. [2021-10-06]. <https://arxiv.org/abs/1511.06434>.
- [180] Song K C, Yan Y H. Micro surface defect detection method for silicon steel strip based on saliency convex active contour model[J]. Mathematical Problems in Engineering, 2013, 2013.
- [181] Lei H W, Wang B, Wu H H, et al. Defect detection for polymeric polarizer based on faster R-CNN[J]. J. Inf. Hiding Multim. Signal Process., 2018, 9(6): 1414-1420.
- [182] Li S Y, Zhao X F, Zhou G Y. Automatic pixel - level multiple damage detection of concrete structure using fully convolutional network[J]. Computer-Aided Civil and Infrastructure Engineering, 2019, 34(7): 616-634.
- [183] Neuhauser F M, Bachmann G, Hora P. Surface defect classification and detection on extruded aluminum profiles using convolutional neural networks[J]. International Journal of Material Forming, 2020, 13(4): 591-603.
- [184] VOC 2007 Dataset[DB/OL]. [2021-10-06]. <https://pjreddie.com/projects/pascal-voc-dataset-mirror>.
- [185] Wu J, Le J, Xiao Z T, et al. Automatic fabric defect detection using a wide-and-light network[J]. Applied Intelligence, 2021, 51(7): 4945-4961.
- [186] Liong S T, Gan Y S, Huang Y C, et al. Automatic defect segmentation on leather with deep learning [EB/OL]. [2021-10-06]. <https://arxiv.org/pdf/1903.12139.pdf>.
- [187] He K M, Gkioxari G, Dollár P, et al. Mask r-cnn[C]// Proceedings of the IEEE international conference on computer vision. Italy: IEEE, 2017: 2961-2969.
- [188] Lin T Y, Maire M, Belongie S, et al. Microsoft coco: Common objects in context[C]//Proceedings of the European conference on computer vision. Zurich, Switzerland: ECCV, 2014: 740-755.
- [189] Badmos O, Kopp A, Bernthaler T, et al. Image-based defect detection in lithium-ion battery electrode using convolutional neural networks[J]. Journal of Intelligent Manufacturing, 2020, 31(4): 885-897.
- [190] damacharla P, Rao A, Ringenberg J, et al. TLU-NET: a deep learning approach for automatic steel surface defect detection[C]//Proceedings of the 2021 International

- Conference on Applied Artificial Intelligence (ICAPAI). Chongqing China: IEEE, 2021: 1-6.
- [191] Aslam M, Khan T M, Naqvi S S, et al. Ensemble convolutional neural networks with knowledge transfer for leather defect classification in industrial settings[J]. IEEE Access, 2020, 8: 198600-198614.
- [192] Tan M X, Le Q. Efficientnet: Rethinking model scaling for convolutional neural networks[C]//Proceedings of the International Conference on Machine Learning. California USA: PMLR, 2019: 6105-6114.
- [193] Huang G, Liu Z, Van D M L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. Hawaii USA: IEEE, 2017: 4700-4708.
- [194] Tschandl P, Rosendahl C, Kittler H. The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions[J]. Scientific data, 2018, 5(1): 1-9.
- [195] Mundt M, Majumder S, Murali S, et al. Meta-learning convolutional neural architectures for multi-target concrete defect classification with the concrete defect bridge image dataset[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach USA: IEEE, 2019: 11196-11205.
- [196] Pan S J, Yang Q. A survey on transfer learning[J]. IEEE Transactions on knowledge and data engineering, 2009, 22(10): 1345-1359.
- [197] Feng C, Liu M Y, Kao C C, et al. Deep active learning for civil infrastructure defect detection and classification[M]//Computing in civil engineering 2017. 2017: 298-306.
- [198] Lv X M, Duan F J, Jiang J J, et al. Deep active learning for surface defect detection[J]. Sensors, 2020, 20(6): 1650.
- [199] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. Hawaii USA: IEEE, 2017: 7263-7271.
- [200] Iandola F N, Han S, Moskewicz M W, et al. SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and < 0.5 MB model size[EB/OL]. [2021-10-06]. <https://arxiv.org/abs/1602.07360>.
- [201] Howard A G, Zhu M, Chen b, et al. Mobilenets: efficient convolutional neural networks for mobile vision applications[J]. computer science-computer vision and pattern recognition, 2017: 1-9.
- [202] Zhang X Y, Zhou X Y, Lin M X, et al. Shufflenet: An extremely efficient convolutional neural network for mobile devices[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. Salt Lake City USA: IEEE, 2018: 6848-6856.
- [203] Chollet F. Xception: Deep learning with depthwise separable convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. Hawaii USA: IEEE, 2017: 1251-1258.
- [204] Choi W, Cha Y J. SDDNet: Real-time crack segmentation[J]. IEEE Transactions on Industrial Electronics, 2019, 67(9): 8016-8025.
- [205] Zhou T, Zhang J B, Su H, et al. EDDs: a series of Efficient Defect Detectors for fabric quality inspection[J]. Measurement, 2021, 172: 108885.
- [206] Lin Z S, Ye H X, Zhan B, et al. An efficient network for surface defect detection[J]. Applied Sciences, 2020, 10(17): 6085.
- [207] Li Y, Xu J B. Electronic product surface defect detection based on a mssd network[C]//Proceedings of the 2020 IEEE 4th Information Technology, Networking, Electronic and Automation Control Conference (ITNEC). Chongqing China: IEEE, 2020, 1: 773-777.
- [208] Sandler M, Howard A, Zhu M L, et al. Mobilenetv2: Inverted residuals and linear bottlenecks [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. Salt Lake City USA: IEEE, 2018: 4510-4520.
- [209] Wu Y, Zhang X D, Fang F Z. Automatic fabric defect detection using cascaded mixed feature pyramid with guided localization[J]. Sensors, 2020, 20(3): 871.
- [210] Tan M, Le Q V. MixConv: Mixed Depthwise Convolutional Kernels [EB/OL]. [2021-10-06]. <https://arxiv.org/pdf/1907.09595.pdf>.
- [211] Huang Y B, Qiu C Y, Wang X N, et al. A compact convolutional neural network for surface defect inspection[J]. Sensors, 2020, 20(7): 1974.
- [212] Zhang A, Wang K C P, Fei Y, et al. Automated pixel-level pavement crack detection on 3D asphalt surfaces with a recurrent neural network[J]. Computer-Aided Civil and Infrastructure Engineering, 2019, 34(3): 213-229.
- [213] Zhao Y D, Hao K R, He H B, et al. A visual long-short-term memory based integrated CNN model for fabric defect image classification[J]. Neurocomputing, 2020, 380: 259-270.
- [214] Simonyan K, Zisserman a. Very deep convolutional networks for large-scale image recognition[j]. int. conf. learn. representat, 2015: 1-14.
- [215] Zhu Z W, Han G J, Jia G Y, et al. Modified densenet for automatic fabric defect detection with edge computing for minimizing latency[J]. IEEE Internet of Things Journal, 2020, 7(10): 9623-9636.
- [216] Chen F C, Jahanshahi M R. NB-CNN: Deep learning-based crack detection using convolutional neural network and Naïve Bayes data fusion[J]. IEEE Transactions on Industrial Electronics, 2017, 65(5): 4392-4400.
- [217] Xu X M, Chen J X, Zhang H D, et al. D4Net: De-deformation defect detection network for non-rigid products with large patterns[J]. Information Sciences, 2021, 547: 763-776.
- [218] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[C]//Proceedings of the NIPS 2014 Deep Learning and Representation Learning Workshop, Montreal, Canada: NIPS, 2014: 1-9.
- [219] Zhang J B, Su H, Zou W, et al. CADN: A weakly supervised learning-based category-aware object detection network for surface defect detection[J]. Pattern Recognition, 2021, 109: 107571.
- [220] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C]//Proceedings of the European Conference on Computer Vision. Online: ECCV, 2020: 213-229.